Datamecum

Modelos fundacionales en visión artificial

Tema 2: Hugging Face

Día 1 del curso

Web del curso	datamecum.sergiovillanuevalopez.com
Práctica	Cuaderno 2 en Colab (2_HF_Intro.ipynb)
Profesor	Sergio Villanueva · Datamecum

2. Hugging Face

Buscar modelos, revisar su licencia y usarlos.

Hugging Face es hoy el **repositorio de referencia** para modelos de IA, datasets, demos interactivas y herramientas de desarrollo. Desde la misma web se busca un modelo, se prueba y se descarga.



Qué es Hugging Face

Hugging Face reúne **cuatro piezas que se usan juntas**.

Model Hub

Catálogo con más de tres millones de modelos preentrenados: visión, lenguaje, audio y multimodales.

Datasets

Más de un millón de datasets públicos para entrenar y evaluar, con una API común de carga y procesamiento.

Spaces

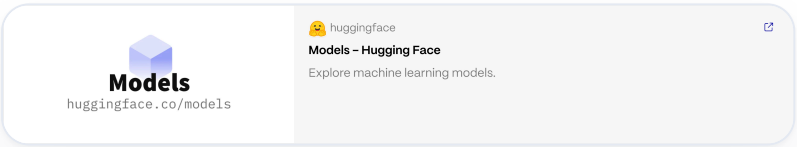
Demos web interactivas, casi siempre con Gradio, que Hugging Face aloja y ejecuta. Pruebas un modelo en segundos sin instalar nada.

Transformers

Librería Python con una misma API de carga, inferencia y fine-tuning para cientos de arquitecturas distintas.

El flujo típico

1. **Buscar modelo**
2. **Probar en Space**
3. **Descargar con Transformers**
4. **Integrar en tu aplicación**



huggingface.co/models

Cómo buscar un modelo

El buscador del Hub tiene estos **filtros**:

- **Tarea:** object-detection, image-classification, text-generation, etc.
- **Licencia:** Apache-2.0, MIT, CreativeML, Research-only.
- **Popularidad:** número de descargas, likes, fecha de última actualización.

La ficha del modelo (model card) es lo primero que hay que leer. Una ficha completa trae:

Descripción y uso

Para qué fue entrenado, qué tareas resuelve, cómo usarlo con código de ejemplo.

Licencia

Términos legales de uso: ¿puedes usarlo comercialmente? ¿Debes atribuir autoría?

Métricas

Resultados en benchmarks estándar, comparación con otros modelos.

Limitaciones

Sesgos conocidos, casos donde falla, advertencias de seguridad y aspectos éticos.

Archivos

Configuración JSON, pesos del modelo (.safetensors preferido), tokenizers, ejemplos.

Las descargas y los likes sirven para descubrir candidatos, no para decidir cuál funciona mejor en tu dominio. La fecha de última actualización avisa de modelos abandonados.

La ficha del modelo

La Model Card contesta si el modelo sirve para tu caso antes de gastar tiempo.

Buscas un clasificador para imágenes médicas. ¿Qué debes hacer primero?

- A Elegir el modelo con más descargas.
- B Filtrar por tarea y revisar la model card con el dominio y licencia en mente.
- C Descargar todos los modelos y comparar solo su tamaño.

Respuesta B. Exacto: la tarea reduce la búsqueda y la documentación permite juzgar la adecuación.

Un dominio sensible obliga a revisar para qué se entrenó el modelo, con qué datos y qué limitaciones declara. El número de descargas no responde a ninguna de esas preguntas.

Licencias

La licencia dice **para qué puedes usar el modelo**: en un producto, en un servicio web o solo para investigar.

Comercial OK

- **Apache-2.0:** muy permisiva, ideal para empresas.
- **MIT:** similar a Apache, aún más simple.
- **BSD:** variantes 2-clause y 3-clause, ambas permisivas.

Con restricciones

- **OpenRAIL/CreativeML:** uso comercial OK, pero con cláusulas de uso responsable.
- **CC BY-SA:** requiere compartir derivados bajo la misma licencia.

No comercial

- **Research Only:** solo investigación académica.
- **CC BY-NC:** prohibido uso comercial.

Caso especial AGPL: algunas familias YOLO populares usan AGPL, que **obliga a publicar el código de la aplicación que lo incorpora** si integras el modelo en una aplicación web o servicio. Si no quieres publicar tu código, busca alternativas con Apache-2.0 como RT-DETR o RF-DETR.

Las condiciones se revisan por artefacto y por versión: el repositorio de código y los pesos publicados pueden llevar licencias distintas, y ambas pueden cambiar entre versiones. Esta clasificación orienta la búsqueda; la decisión final se toma leyendo la licencia vigente del artefacto concreto.

Licencia según el uso

La misma licencia cambia de respuesta según lo que vayas a hacer con el modelo.

AGPL

Servicio web o SaaS

Permitido con condiciones

La cláusula de red obliga a publicar el código de la aplicación que lo incorpora aunque solo la ofrezcas por web. Alternativas Apache-2.0: RT-DETR o RF-DETR.

Orientación para buscar, no asesoramiento legal. La licencia real se lee en el artefacto y la versión que vayas a usar.

La tabla recoge lo que explica la diapositiva anterior. Los tres casos que más sorprenden: AGPL no obliga a nada mientras no distribuyas ni sirvas el modelo, pero sí en cuanto lo expones por web; una licencia no comercial tampoco vale para un prototipo interno de empresa, porque el propósito ya es comercial; y CC BY-SA permite vender, pero obliga a publicar los derivados con la misma licencia.

Licencia del código y de los pesos

Un repositorio permisivo no garantiza que los pesos lo sean.

Un repositorio tiene código permisivo, pero los pesos incluyen otra licencia. ¿Qué debes revisar?

- A Solo la licencia del código.
- B Las condiciones de código, pesos, datos y uso de la versión concreta.
- C Nada si el modelo se puede descargar sin pagar.

Respuesta B. Exacto: cada recurso puede añadir términos distintos.

Conviene revisar la licencia del repositorio, la del checkpoint concreto y la de los datos de entrenamiento cuando se declara, además de la versión a la que se aplican.

Qué pasa al cargar un modelo

Lo que hace la librería Transformers al cargar un modelo:

1 **Hub remoto**

El modelo vive en Hugging Face Hub identificado por su nombre (ej: «facebook/detr-resnet-50»).

2 **Descarga a caché**

Primera ejecución: descarga config.json, pesos .safetensors, y metadatos a ~/.cache/huggingface/

3 **Carga en memoria**

El modelo se instancia en RAM/VRAM según el dispositivo (CPU/GPU) que especifiques.

4 **Inferencia**

Procesas inputs y obtienes predicciones. Puedes usar GPU y mixed precision para acelerar.

Buenas prácticas

- **Seguridad:** prefiere .safetensors sobre .bin; los .bin usan pickle, que puede ejecutar código al cargarse.
- **Offline:** predescarga con snapshot_download, controla cache_dir.
- **Rendimiento:** usa float16 y device="cuda" cuando tengas GPU.
- **Pipelines:** para pruebas rápidas, usa pipeline("task"); en producción, clases específicas dan más control.

Código: pipeline

```
from transformers import pipeline

# 1. Cargar modelo (automáticamente baja config y pesos)
detector = pipeline("object-detection", model="PekingU/rtdetr_r50vd")

# 2. Inferencia
results = detector("imagen.jpg")

# 3. Resultado
print(results)  # [{'label': 'cat', 'score': 0.99, 'box': {...}}]
```

transformers se encarga de la descarga, el preprocesado y la inferencia.

El identificador del modelo determina qué arquitectura y qué preprocesador se instancian. Para reproducibilidad conviene fijar también la revisión. En producción, las clases específicas permiten controlar batching, dispositivo, precisión y formato de salida.

Un pipeline por tarea

Elige qué quieres hacer y dónde vas a ejecutarlo. El código de abajo es el que se pega en el cuaderno, con el modelo del Hub que corresponde a esa tarea.

Qué quieres hacer

- **Clasificar la imagen entera**
- Detectar los 80 objetos de COCO
- Decidir entre textos que yo escribo
- Localizar objetos descritos con palabras
- Describir la escena en una frase

Dónde lo ejecutas

CPU | GPU

```
from transformers import pipeline

pipe = pipeline(
    "image-classification",
    model="google/vit-base-patch16-224",
    device="cpu",
)
salida = pipe("foto.jpg")
print(salida[:3])
```

ViT base, 86 M de parámetros. Devuelve etiquetas de las 1.000 de ImageNet, así que solo sirve si tus clases están ahí. Arranca en cualquier portátil. Cuenta con hasta unos segundos por imagen en los modelos grandes.

Las cinco tareas usan la misma llamada y cambian el identificador del modelo, que es lo que hace el Hub cómodo para probar. Las dos que aceptan `candidate_labels` (CLIP y Grounding DINO) son las que permiten cambiar de clases sin reentrenar. El argumento `device` admite «cpu» o «cuda»; con varias tarjetas se indica el índice.

Qué te ahorra un pipeline

Conviene saber qué pasos quedan ocultos antes de llevarlo a producción.

¿Qué simplifica un pipeline de Transformers?

- A La preparación de entrada y la ejecución de una tarea común.
- B La necesidad de conocer la licencia y la model card.
- C El entrenamiento de cualquier modelo sin datos.

Respuesta A. Exacto: el pipeline agrupa pasos frecuentes para una primera prueba.

El pipeline reúne preprocesado, inferencia y posprocesado para una tarea común. No elige el modelo por ti ni garantiza el mejor rendimiento en tu dominio.

Cargar un modelo para probar y para producción

Dos formas de cargar el mismo modelo: rápida para probar, específica para producción.

```
# Para probar: el pipeline resuelve pre y posprocesado
from transformers import pipeline

detector = pipeline("object-detection", model="PekingU/rtdetr_r50vd")
print(detector("mi_imagen.jpg"))

# Para producción: control sobre dispositivo, precisión y salida
import torch
from transformers import AutoImageProcessor, AutoModelForObjectDetection

model_id = "PekingU/rtdetr_r50vd"
revision = "main"  # para reproducir, pon aquí el hash de un commit
device = "cuda" if torch.cuda.is_available() else "cpu"

processor = AutoImageProcessor.from_pretrained(model_id, revision=revision)
model = AutoModelForObjectDetection.from_pretrained(model_id, revision=revision)
model = model.to(device).eval()
```

- Fija **revision** con el hash de un commit (pestaña «Files and versions» del modelo) si quieres reproducir el resultado dentro de seis meses. «main» no fija nada: avanza cada vez que el autor sube cambios.
- Descarga a caché la primera vez, a `~/.cache/huggingface/`. Para entornos sin red, `snapshot_download` antes.
- Prefiere los pesos en **.safetensors** cuando el repositorio los ofrezca.

Memoria de GPU

Primera pregunta al elegir modelo, y se responde con una multiplicación.

Parámetros del modelo **300 M**

Precisión

float16 o bfloat16

T4 · 16 GB

L4 · 24 GB

A100 · 40 GB

Colab gratis · 15 GB

Portátil · 8 GB

Memoria estimada para inferencia

0,8 GB

Solo los pesos

0,6 GB

Cabe en 5 de las 5 tarjetas de la lista, contando solo inferencia.

Pesos por precisión más un 35 % de margen para activaciones y fragmentación, con lotes pequeños. Entrenar necesita bastante más, porque además guarda gradientes y estados del optimizador.

La cuenta es directa: parámetros por bytes de cada precisión. En float32 cada parámetro ocupa 4 bytes, en float16 dos y cuantizado a int8 uno. Por eso pasar de float32 a float16 es lo primero que se prueba cuando un modelo no entra, y suele costar muy poca calidad en inferencia.

Modelos de visión para empezar

Filtra por tarea y por licencia, que son los dos criterios que descartan antes.

`PekingU/rtdetr_r50vd`	Detección COCO, tiempo real	**Apache-2.0**	~42 M
`facebook/detr-resnet-50`	El DETR original, de referencia	**Apache-2.0**	~41 M
`hustvl/yolos-small`	Detección con ViT puro	**Apache-2.0**	~31 M
`IDEA-Research/grounding-dino-base`	Cajas a partir de una frase	**Apache-2.0**	~233 M
`google/owlv2-base-patch16`	Vocabulario abierto por texto	**Apache-2.0**	~154 M
`facebook/sam2.1-hiera-large`	Segmentación con prompts, imagen y vídeo	**Apache-2.0**	~224 M
`facebook/dinov2-base`	Features densas sin etiquetas	**Apache-2.0**	~86 M
`openai/clip-vit-base-patch32`	Imagen y texto en un espacio común	**MIT**	~151 M
`briaai/RMBG-1.4`	Recorte de fondo con canal alfa	**No comercial**	~44 M

Lista consultada el 17 de septiembre de 2026 y pensada como punto de partida, no como ranking. Los tamaños son aproximados y la licencia debe confirmarse en la ficha del modelo y de sus pesos antes de usarlo, porque puede cambiar entre versiones. Fíjate en el caso de RMBG-1.4: excelente para recortar fondo, pero su licencia no permite uso comercial sin acuerdo.

Spaces: demos en el navegador

Un Space es una demo web del modelo, ya montada. Subes una foto y ves la salida, sin instalar nada.

Quitar el fondo

Sube una foto de producto y descarga el recorte con transparencia. Es el modelo del tema 6 puesto a trabajar.

Space de BRIA RMBG 1.4

Profundidad de una sola foto

Sube cualquier foto y mira el mapa de distancias. Prueba con espejos o cristales, que hacían fallar a la versión anterior, y comprueba si acierta.

Space de Depth Anything V2

Detectar escribiendo la clase

Página de la tarea, con los modelos, los datasets y los Spaces que están vivos hoy. Escribe «una caja de cartón» y mira qué encuentra.

Tarea: detección zero-shot

Segmentar

La misma idea para máscaras: modelos de segmentación semántica, de instancias y promptable, con demos que puedes abrir al momento.

Tarea: segmentación de imagen

Puntos clave

Pose de personas y puntos de interés para matching, con más de 400 modelos publicados y sus demos.

Tarea: detección de puntos clave

Preguntar sobre una imagen

Los modelos que reciben imagen y texto y responden. Sube una foto de una etiqueta y pídele los campos en JSON.

Tarea: imagen y texto a texto

Dos avisos antes de subir nada. Un Space público procesa tu imagen en el servidor de quien lo publicó, así que ahí no van fotos de cliente, de personas identificables ni de piezas bajo acuerdo de confidencialidad. Y los Spaces se duermen, se rompen y desaparecen: por eso los enlaces de arriba apuntan a la página de la tarea, que sigue viva aunque una demo concreta caiga.

Un Space es un repositorio con una aplicación (Gradio, Docker o HTML estático) que Hugging Face construye y ejecuta. En el hardware gratuito, CPU Basic, se duerme tras un rato sin visitas, de ahí que a veces tarde en arrancar o falle al construirse. Con el botón de duplicar tienes tu propia copia para cambiarle el modelo, la forma más rápida de enseñar un resultado a alguien que no programa. Ten en cuenta que crear un Space con Gradio o Docker pide hoy un plan de pago, salvo hasta dos Spaces de Gradio en ZeroGPU para cuentas gratuitas; los de HTML estático son gratis. Para un piloto interno conviene duplicarlo en privado en lugar de usar el público.

Antes de quedarte con un modelo del Hub

Siete cosas que comprobar antes de elegirlo.

- [ ] **La tarea coincide**
  La etiqueta del Hub dice lo que necesitas, no algo parecido.
- [ ] **La licencia permite tu uso**
  Comprobada en el repositorio y en los pesos, para la versión que vas a usar.
- [ ] **La ficha declara limitaciones**
  Sesgos, casos donde falla, datos de entrenamiento. Si no dice nada, desconfía.
- [ ] **Cabe en tu hardware**
  Con la precisión que vas a usar y con margen para el lote.
- [ ] **Formato de pesos seguro**
  .safetensors antes que .bin.
- [ ] **Revisión anotada**
  Identificador y revisión guardados para poder reproducir.
- [ ] **Probado con tus datos**
  Una decena de imágenes tuyas dicen más que cualquier métrica publicada.

Cuaderno 2: Hugging Face

Los ejercicios de este tema están en el cuaderno.

1. El Hub y la ficha de un modelo
2. pipeline y lo que hay dentro
3. Guardar un modelo en una carpeta
4. Licencias
5. Ejercicios: otro clasificador y el detector del cuaderno 1 por dentro

Abrir en Colab ↗

En Colab: Archivo, Guardar una copia en Drive, y Entorno de ejecución, GPU T4.