Datamecum

Modelos fundacionales en visión artificial

Tema 5: Segmentación con SAM

Día 2 del curso

Web del curso	datamecum.sergiovillanuevalopez.com
Práctica	Cuaderno 5 en Colab (5_SAM.ipynb)
Profesor	Sergio Villanueva · Datamecum

5. SAM: Segment Anything (v1, v2, v3)

Segmentación universal en imagen y vídeo, con prompts.

SAM (Segment Anything Model) segmenta cualquier objeto de cualquier imagen a partir de indicaciones sencillas (puntos, cajas, máscaras), sin entrenar para clases concretas. Desde SAM 2 hace lo mismo en vídeo, manteniendo el objeto entre fotogramas.



¿Qué es segmentación?

La segmentación de imágenes es una tarea básica en visión artificial que da más que una caja: asigna una etiqueta a cada píxel de una imagen, delimitando el contorno exacto de los objetos y el fondo.

Tipos de segmentación

Semántica

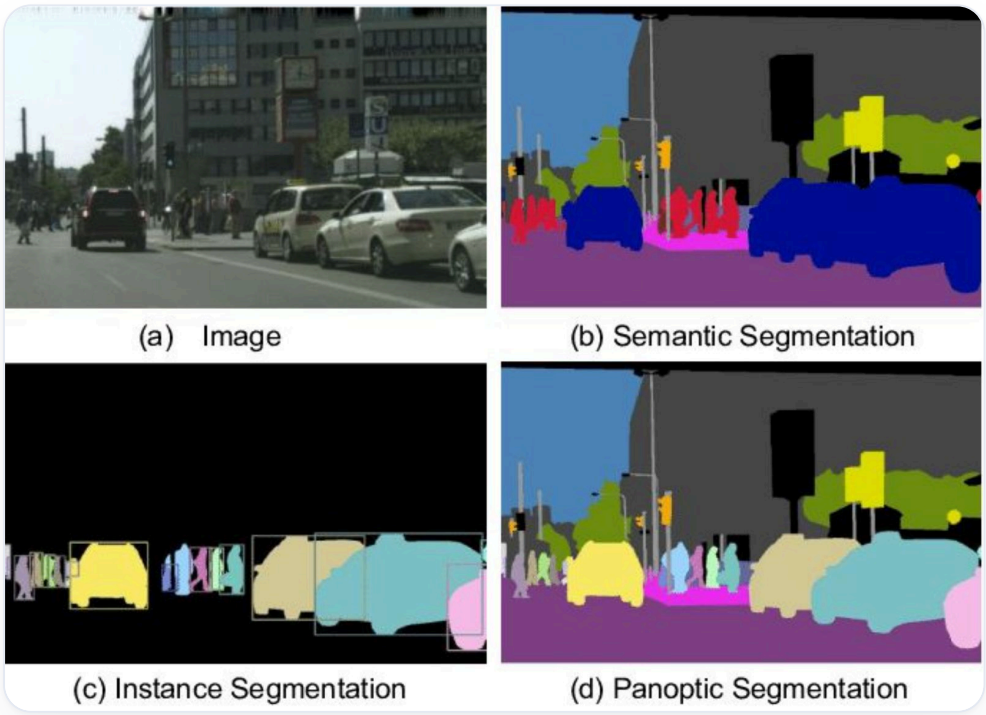
Cada píxel se clasifica en una categoría (por ejemplo, «coche», «persona», «fondo»). No distingue entre instancias individuales del mismo tipo de objeto: todos los coches reciben la misma máscara y etiqueta.

Por instancias

Cada objeto individual detectado recibe una máscara única y su propia etiqueta. Permite distinguir entre objetos del mismo tipo, como «coche 1», «coche 2», «persona A», «persona B».

Panóptica

Combina la segmentación semántica y por instancias. Asigna una máscara única y una etiqueta a cada instancia de objeto cubriendo toda la imagen. Es la más completa pero también la más compleja.



Cómo funciona SAM

SAM tiene una parte pesada que mira la imagen una sola vez y una parte ligera que responde a cada clic. Por eso, tras el primer cálculo, cada indicación se resuelve al momento.

Codificador de imagen (lo pesado)

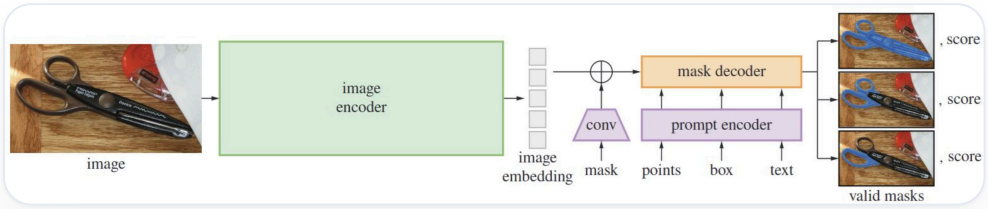
Un ViT grande convierte la imagen en un mapa de características. Se ejecuta una vez por imagen y el resultado se reutiliza para todos los clics.

Codificador de indicaciones

Convierte los puntos, las cajas o una máscara previa en vectores. Es casi instantáneo.

Decodificador de máscaras

Junta las dos cosas y devuelve tres máscaras candidatas (objeto, parte y subparte) con su puntuación. Tarda unos 50 ms, incluso en el navegador.



SAM 1 no entiende texto. Para segmentar «el coche rojo» hace falta otro modelo que dé la caja, como Grounding DINO. SAM 2 añade memoria para vídeo y SAM 3 acepta texto: lo veis en la pantalla siguiente.

Evolución: SAM → SAM 2 → SAM 3

SAM trabaja con imágenes, SAM 2 añade vídeo y SAM 3 acepta un concepto escrito o un ejemplo.

1

2023 · SAM 1

Segmentación universal en imagen con prompts de puntos y cajas. Dataset SA-1B: unos 11 millones de imágenes y 1.100 millones de máscaras.

2

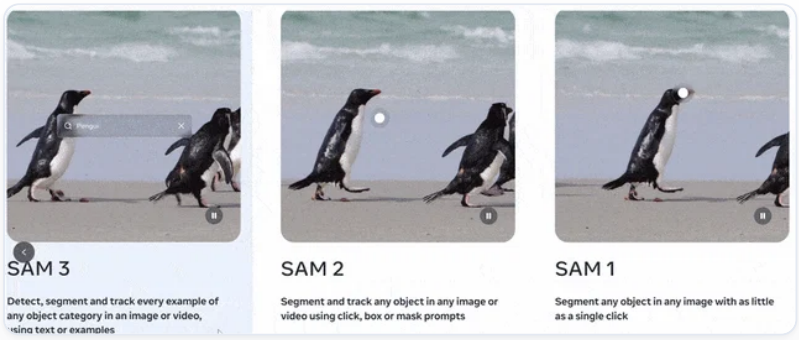
2024 · SAM 2

Extiende a vídeo con memoria en streaming; más preciso y hasta 6 veces más rápido que SAM 1 en imagen. Dataset SA-V: unos 51.000 vídeos y 643.000 masklets.

3

2025 · SAM 3

Modelo unificado que detecta, segmenta y sigue todas las instancias de un concepto, dado por texto o por ejemplos, en imagen y vídeo.



Motor de datos: 1.100 millones de máscaras

SA-1B, el dataset con el que se entrenó SAM, salió de un «motor de datos»: un ciclo en el que personas y modelo anotan juntos y el modelo va haciendo cada vez más parte del trabajo.

1

Anotación asistida

Personas anotan con una herramienta que ya usa una primera versión de SAM: hacen clics y corrigen la máscara. El modelo se reentrena con lo anotado.

2

Anotación semiautomática

SAM marca solo los objetos que tiene claros y las personas añaden los que faltan. Así el dataset gana variedad, y el modelo se vuelve a reentrenar.

3

Anotación totalmente automática

Cuando el modelo ya es fiable, anota imágenes completas de forma autónoma. Solo se aceptan las máscaras con alta confianza, permitiendo un escalado masivo de datos.

El resultado: el 99,1 % de las máscaras de SA-1B las generó el propio SAM en la fase automática.

Segmentar con indicaciones (promptable segmentation)

Le indicas a SAM qué quieres segmentar con un punto, una caja u otra indicación, y no hace falta reentrenarlo.

Tipos de prompts y sus capacidades

Puntos

- **Múltiples puntos:** incluye o excluye áreas específicas para refinar la máscara deseada.
- **Precisión:** útil para objetos ambiguos o con bordes complejos.

Cajas (bounding box)

- **Delimitación amplia:** dibuja una caja alrededor del objeto; SAM la convierte en una máscara precisa.
- **Rapidez:** ideal para segmentación rápida de objetos bien definidos.

Máscara inicial

- **Refinamiento:** proporciona una máscara aproximada (rough) y el modelo perfecciona los bordes y rellena huecos.
- **Perfeccionamiento:** útil para mejorar segmentaciones previas o manuales.

Texto

- **SAM 1 y SAM 2:** mediante adaptadores (CLIP o Grounding DINO), se puede usar texto como «el coche rojo».
- **SAM 3 (nativo):** acepta directamente frases nominales cortas («autobús amarillo») y segmenta todas las instancias. Para frases con razonamiento, como «el de la izquierda», hace falta un VLM.

Ejemplar (crop)

- **SAM 3:** a partir de un recorte de ejemplo, segmenta todas las instancias del mismo concepto en la imagen o vídeo.
- **Generalización:** ideal para tareas de conteo o seguimiento de objetos idénticos.

Segment everything

- **Cobertura completa:** genera una máscara para cada objeto detectable en la imagen sin prompts específicos.
- **Análisis exhaustivo:** útil para la inspección completa de escenas complejas.

Meta AI publica un **Segment Anything Playground**, un espacio interactivo para probar estos prompts sobre medios propios.

Punto, caja o texto

Un punto devuelve una instancia; un concepto en texto devuelve todas las que coinciden.



Máscaras precalculadas para esta demostración con un algoritmo clásico a partir de una caja. En el cuaderno las genera SAM.

Qué le indicas al modelo

- **Un punto en la sandía izquierda**
- Un punto en la sandía derecha
- Texto: «sandía»
- Una caja sobre las limas
- Un punto en la piña

Un punto señala una región concreta, así que el modelo devuelve esa sandía y no la otra.

Instancias segmentadas **1**

Esta página recoge el estado con un punto sobre la sandía izquierda. Lo que conviene retener es una diferencia de interfaz: un punto o una caja identifican *dónde*, y devuelven la instancia que hay ahí; un concepto en texto o un ejemplar identifican *qué*, y devuelven todas las coincidencias. SAM 1 y SAM 2 admiten de forma nativa lo primero, y para lo segundo necesitan un modelo externo que traduzca el texto; SAM 3 incorpora el texto y los ejemplares como prompts propios. Las máscaras de esta demostración se calcularon con GrabCut a partir de una caja, no con SAM: el cuaderno del tema las genera con el modelo real.

Qué es una máscara

Desliza para quitar el fondo. Lo que queda es la salida de la segmentación: una lista de píxeles por instancia, cada una con su contorno, no un recorte rectangular.



Cuatro instancias con su contorno. Fíjate en las hojas de la piña y en el borde entre las dos filas de limas: ahí es donde se nota la calidad del recorte.

> Una máscara pesa poco y se guarda comprimida (RLE en COCO). Con ella puedes contar objetos, medir su área en píxeles o recortarlos con transparencia, cosas que una caja no permite.

La imagen de la derecha se compone multiplicando la foto por la unión de las cuatro máscaras, que es lo mismo que hace cualquier herramienta de recorte automático. Las máscaras están precalculadas con GrabCut a partir de una caja, no con SAM: el cuaderno del tema las genera con el modelo real. Un detalle que se ve al deslizar: el contorno de las limas rodea el montón entero porque la indicación fue una caja sobre el montón, no sobre una lima suelta.

Empezar con un punto

El punto positivo señala una región que debe pertenecer a la máscara.

Quieres segmentar una manzana entre otras frutas. ¿Qué prompt sirve para empezar?

- A Un punto positivo dentro de la manzana.
- B El nombre de la clase sin imagen.
- C Una métrica de precisión.

Respuesta A. Exacto: indica qué objeto quieres incluir.

La primera indicación puede admitir varias interpretaciones: objeto completo, parte o subparte. Por eso algunas versiones devuelven varias máscaras candidatas con puntuaciones.

Corregir sin volver a entrenar

Los nuevos clics añaden información sobre qué incluir y qué excluir.

La máscara incluye parte del fondo. ¿Qué harías?

- A Añadir un punto negativo sobre el fondo.
- B Subir la temperatura del modelo.
- C Cambiar el nombre del objeto.

Respuesta A. Exacto: el punto negativo señala qué región excluir.

En vídeo con SAM 2, una corrección puede actualizar la memoria y propagarse. La interacción debe evaluarse por calidad final y por número de clics o tiempo requerido.

Cuándo usar (y cuándo no) SAM

Úsalo si… (ideal para flexibilidad y zero-shot)

- **Segmentación zero-shot crítica:** necesitas segmentar objetos desconocidos, raros o que no existían en tu dataset de entrenamiento (por ejemplo, microscopía o imagen submarina).
- **Vídeo y coherencia temporal:** requieres rastrear objetos que se mueven, ocultan y reaparecen sin entrenar un tracker específico, gracias a la memoria de SAM 2 y 3.
- **Interacción humana (human-in-the-loop):** estás construyendo herramientas de anotación de datos o edición donde el usuario refina el resultado con clics o cajas.
- **Búsqueda por conceptos (SAM 3):** necesitas encontrar todas las instancias de un concepto abstracto («tornillos oxidados») usando texto o ejemplos visuales, no solo puntos.
- **Escasez de datos:** no tienes miles de máscaras anotadas para entrenar un modelo supervisado tradicional.

Evítalo si… (mejor usar modelos supervisados clásicos)

- **Restricciones de hardware extremas (edge):** necesitas inferencia en milisegundos en dispositivos IoT o móviles antiguos. SAM 3 es el más exigente: su paper da unos 30 ms por imagen con más de cien objetos en una H200, una GPU de centro de datos. Mide memoria y latencia en tu equipo.
- **Entorno cerrado y repetitivo:** si tu problema es «detectar botellas en una cinta transportadora», con clases fijas y fondo controlado, un modelo ligero como RF-DETR-Seg será mucho más rápido y barato de desplegar.
- **Razonamiento complejo:** SAM 3 entiende frases nominales simples. Si necesitas lógica compleja, necesitas un VLM.

SAM no dice qué es

SAM marca el contorno, pero no sabe qué objeto es. El nombre lo tiene que poner otro modelo.

Necesitas saber qué especie aparece y segmentarla.

- A Combinar una señal de categoría con SAM.
- B Usar solo una máscara sin revisar.
- C Eliminar los prompts.

Respuesta A. Exacto: SAM aporta la máscara, otra parte debe aportar la categoría.

SAM resulta valioso con poca anotación, interacción humana o vídeo. Un modelo supervisado pequeño puede ser más rápido y barato para clases estables y fondos controlados. Siempre hay que evaluar bordes, objetos pequeños, oclusiones y consumo de memoria.

Segmentar con un punto

Obtener la máscara de un objeto indicando un punto.

```
import torch
from PIL import Image
from transformers import Sam2Model, Sam2Processor

model_id = "facebook/sam2.1-hiera-small"  # 184 MB; la large pesa 898 MB
model = Sam2Model.from_pretrained(model_id).eval()
processor = Sam2Processor.from_pretrained(model_id)

image = Image.open("mi_imagen.jpg").convert("RGB")
puntos = [[[[450, 300]]]]          # un punto, en coordenadas de la imagen
etiquetas = [[[1]]]                # 1 incluye, 0 excluye

inputs = processor(images=image, input_points=puntos,
                   input_labels=etiquetas, return_tensors="pt")
with torch.no_grad():
    salida = model(**inputs, multimask_output=True)

mascaras = processor.post_process_masks(salida.pred_masks,
                                        inputs["original_sizes"])[0]
print(mascaras.shape, salida.iou_scores)
```

- **multimask_output** devuelve tres candidatas para resolver la ambigüedad entre objeto, parte y subparte. Quédate con la de mayor `iou_scores` o enséñaselas al usuario.
- Para **corregir**, añade otro punto con etiqueta 0 donde la máscara invada el fondo y vuelve a llamar.
- El encoder de imagen es lo caro y se ejecuta una vez. Los clics posteriores son casi gratis.

¿Qué versión de SAM necesitas?

Las tres segmentan, pero no aceptan las mismas indicaciones ni el mismo medio.

¿Sobre qué trabajas?

- (●) Imágenes sueltas
- ( ) Vídeo, y hay que seguir el objeto

¿Cómo vas a señalar lo que buscas?

- (●) Con clics o cajas
- ( ) Escribiendo qué es, o con un recorte de ejemplo

SAM 1 basta

Imagen y prompts espaciales es justo su caso. Es el más sencillo de desplegar y el encoder se ejecuta una vez por imagen.

Si ya tienes SAM 2 montado, úsalo igualmente: en imagen también es más rápido.

SAM 2

Su banco de memoria mantiene la identidad del objeto entre fotogramas y aguanta oclusiones. Una corrección en un fotograma se propaga al resto.

`facebook/sam2.1-hiera-small`, o la `large` si el borde importa más que la velocidad

SAM 3, o SAM 2 con un detector delante

SAM 3 acepta texto y ejemplares de forma nativa y devuelve todas las instancias del concepto. La alternativa clásica es Grounding DINO produciendo cajas que alimentan a SAM 2.

Esa combinación es la que monta el cuaderno del tema.

SAM 3

Es el único que une las dos cosas: detecta por concepto y sigue las instancias en el tiempo, con el detector reiniciando al tracker cuando lo pierde.

Cuenta con que es el más exigente en hardware de los tres.

Antes de usar SAM

Seis cosas que probar antes de montarlo.

- [ ] **Bordes difíciles probados**
  Pelo, transparencias, objetos muy pequeños. Ahí es donde se cae la máscara.
- [ ] **Ambigüedad resuelta**
  Decide si te quedas con la máscara de mayor puntuación o le enseñas las tres al usuario.
- [ ] **Coste de interacción medido**
  Cuántos clics de media hacen falta para una máscara aceptable.
- [ ] **Encoder reutilizado**
  Una vez por imagen, no una por clic. Es la diferencia entre fluido y lento.
- [ ] **Reconocimiento resuelto aparte**
  SAM delimita pero no nombra. Decide quién pone la etiqueta.
- [ ] **Alternativa ligera comparada**
  Con clases fijas y fondo controlado, un modelo supervisado pequeño puede salir mejor y más barato.

Cuaderno 5: SAM

Los ejercicios de este tema están en el cuaderno.

1. Segmentar con un punto y afinar con varios
2. Recortar y pegar un objeto
3. Segmentar por texto: Grounding DINO y SAM 2
4. Segmentar con instrucciones: Qwen3.5 y SAM 2
5. Búsqueda semántica con SAM y CLIP
6. Ejercicio: el perímetro del lago de Central Park

Abrir en Colab ↗

En Colab: Archivo, Guardar una copia en Drive, y Entorno de ejecución, GPU T4.