Datamecum

Modelos fundacionales en visión artificial

Tema 6: Otras tareas de visión

Día 2 del curso

Web del curso	datamecum.sergiovillanuevalopez.com
Práctica	Cuaderno 6 en Colab (6_Otras_Tareas.ipynb)
Profesor	Sergio Villanueva · Datamecum

6. Otras tareas de visión

Seis tareas más, cada una con su modelo fundacional. Es el tema extra: si no da tiempo a terminarlo en clase, queda para casa.

Estimación de pose

Identificar y localizar puntos clave del cuerpo humano o de objetos en imágenes y vídeos.

Superresolución

Mejorar la calidad y resolución de imágenes o vídeos, a menudo a partir de datos de baja resolución.

Estimación de profundidad

Calcular la distancia de los objetos en una escena respecto a la cámara, creando mapas de profundidad.

OCR moderno

Extraer texto de imágenes y documentos, transformándolo en datos editables y buscables.

Eliminación de fondo

Segmentar y eliminar automáticamente el fondo de una imagen, aislando el objeto principal.

Correspondencias entre imágenes

Encontrar correspondencias o similitudes entre dos o más imágenes para tareas como la localización o el reconocimiento.

Estimación de pose humana

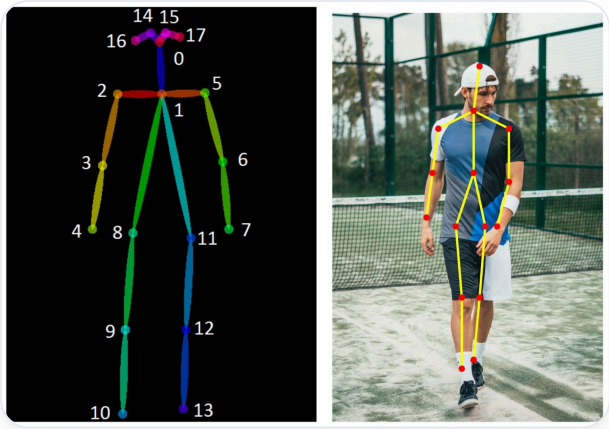
Localizar los puntos del cuerpo de cada persona: hombros, codos, rodillas…

¿Qué es? Tarea de visión que localiza articulaciones clave (keypoints) para modelar la postura y el movimiento.

El estándar (COCO-17): se buscan típicamente 17 puntos.

- **Cabeza:** nariz, ojos (2), orejas (2).
- **Tren superior:** hombros (2), codos (2), muñecas (2).
- **Tren inferior:** caderas (2), rodillas (2), tobillos (2).

El output: una lista de coordenadas (x, y) más un score de confianza por punto.



> Con esos puntos ya se pueden medir ángulos, contar repeticiones o detectar que alguien se ha caído.

Enfoques de modelado: top-down vs. bottom-up

Cuál conviene según cuánta gente haya en la imagen.

Top-down (alta precisión)

Proceso: primero detecta personas (cajas), luego estima la pose dentro de cada una.

Ejemplos: HRNet, ViTPose.

- Pros: máxima precisión, robustez a distintas escalas.
- Contras: lento en grandes aglomeraciones, con coste lineal en el número de personas.

Single-stage (el equilibrio moderno)

Proceso: redes como YOLO-Pose predicen cajas y puntos simultáneamente en una sola pasada (end-to-end).

- Ventaja: velocidad en tiempo real con precisión competitiva, ideal para dispositivos edge.

Bottom-up (alta velocidad)

Proceso: detecta todos los puntos clave de la imagen a la vez, luego los agrupa en personas.

Ejemplo: OpenPose.

- Pros: velocidad constante, independiente del número de personas.
- Contras: menos preciso, el agrupamiento de puntos es complejo.

Modelos de pose

Los que más vais a encontrar.

1. **MediaPipe (Google)**

   Funciona bien en CPU y en el móvil. Pensado para fitness, filtros AR y escenas con una o pocas personas cerca de la cámara. Tiene también modelos para manos y cara.

2. **YOLO-Pose (Ultralytics)**

   YOLOv8, YOLO11 y YOLO26 en versión pose: varias personas en una pasada, buen equilibrio entre velocidad y precisión y fáciles de reentrenar. Licencia AGPL-3.0, como el resto de Ultralytics (tema 1).

3. **OpenPose (CMU)**

   El pionero académico que estableció las bases. Aunque influyente, hoy en día es computacionalmente pesado en comparación con opciones más modernas.

4. **HRNet**

   Prioridad en precisión extrema. Cuando la exactitud es crítica (análisis médico, biomecánico) y la velocidad de inferencia es secundaria.

5. **ViTPose (el del cuaderno)**

   Top-down sobre un ViT sencillo: en el cuaderno, RT-DETR encuentra a las personas y ViTPose les pone los 17 puntos. Licencia Apache 2.0.

Métrica OKS

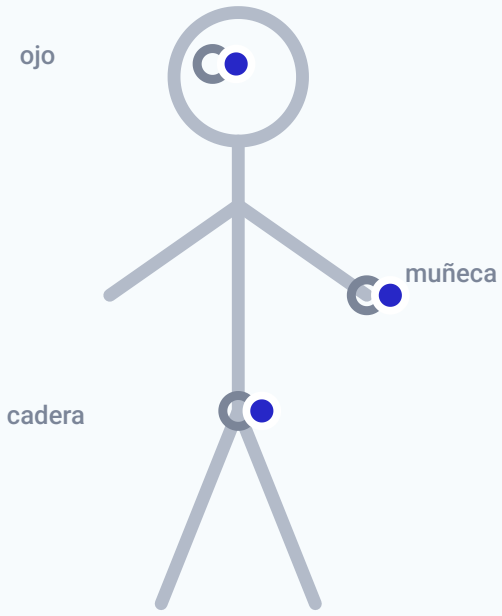
OKS (Object Keypoint Similarity) hace con los esqueletos lo que IoU hace con las cajas: convierte la distancia entre cada punto predicho y el real en una puntuación de 0 a 1, corregida por el tamaño de la persona y por lo difícil que es marcar esa articulación.

Por eso **el mismo error no penaliza igual**: 5 píxeles de error en el ojo, que los anotadores marcan con mucha precisión, cuestan bastante más que 5 píxeles en la cadera, cuya posición exacta es más difícil de fijar.



OKS: error, articulación y escala

La tolerancia depende de la articulación y de la escala de la persona. Mueve las dos cosas y mira cuándo la pose deja de contar como acierto.



El muñeco mide siempre lo mismo y representa a la persona entera: si la persona encoge, el mismo error en píxeles se ve mayor sobre ella.

Cuenta como acierto

OKS del esqueleto	Umbral de acierto
0,92	0,50

Ojo

0,80

Muñeca

0,96

Cadera

0,99

Con escala de 150 px, 5 px dejan el ojo en 0,80 y la cadera en 0,99. El ojo baja de 0,50 a partir de 9 px.

Esto explica el fallo más habitual en planta: el modelo va bien con la persona cerca y se desmorona con la persona al fondo, aunque el error en píxeles sea el mismo. Las dos salidas son acercar la cámara o trabajar en top-down, detectando primero a cada persona y recortándola para que llegue grande al modelo de pose.

Esta página recoge el estado con 5 px de error y escala de 150 px. La escala de COCO es la raíz del área de la persona, y el OKS de la pantalla promedia solo tres articulaciones para que se vea el efecto. Cada articulación tiene un margen propio, medido por lo que discrepan los anotadores humanos al marcarla: la cadera tolera más de cuatro veces el error antes de penalizar lo mismo. La escala entra dividiendo, de modo que la tolerancia en píxeles es proporcional al tamaño de la persona: en una persona de 60 px el ojo baja de 0,50 a partir de 4 px, y en una de 400 px, a partir de 24 px. El OKS del esqueleto es la media de los puntos visibles, y sustituye al IoU cuando se calcula AP para pose: COCO promedia AP con umbrales de 0,50 a 0,95, así que el 0,50 de esta pantalla es el criterio más indulgente de los diez.

La tolerancia de cada punto

La tolerancia de cada articulación sale de cómo de acuerdo se ponen los anotadores humanos.

Dos articulaciones fallan cinco píxeles. ¿Penaliza OKS igual las dos?

- A No: depende del tamaño de la persona y de la articulación.
- B Sí: solo cuenta la distancia en píxeles.
- C Sí, salvo que haya varias personas.

Respuesta A. Exacto: cinco píxeles pesan más en una persona pequeña y en un punto fácil de marcar, como el ojo.

Las constantes por articulación se estimaron midiendo la dispersión entre anotadores. Donde las personas coinciden mucho, como los ojos, el modelo tiene menos margen.

Para qué se usa la pose

Ejemplos en deporte, industria y salud.

Deporte y fitness

- **Entrenador IA:** conteo preciso de repeticiones (sentadillas, flexiones…).
- **Análisis de técnica:** medición de ángulos corporales para prevenir lesiones.
- Por ejemplo, Peloton Guide cuenta repeticiones con una cámara.

Seguridad industrial y ergonomía

- **Detección de posturas peligrosas:** identificar movimientos de riesgo al levantar peso.
- **«Hombre caído»:** alertas de seguridad en tiempo real en entornos peligrosos.
- **Optimización:** mejora de la eficiencia en líneas de montaje.

Salud y rehabilitación

- **Fisioterapia remota:** validación de ejercicios en casa sin supervisión presencial.
- **Análisis de marcha:** detección temprana de patologías neurológicas o musculoesqueléticas.

El gran reto: oclusiones y reconstrucción 3D

El problema: la estimación de pose se complica cuando partes del cuerpo se ocultan entre sí o tras otros objetos, y se pierde información.

La solución: modelos avanzados emplean memoria temporal para rastrear y predecir oclusiones, o realizan inferencia 3D para «imaginar» las partes ocultas basándose en la anatomía y el contexto.



OCR: leer texto y sacar datos de documentos

De Tesseract a TrOCR y los VLM.

El pasado: enfoque clásico (Tesseract)

Metodología: hasta la versión 3 segmentaba caracteres con reglas y contornos; desde la 4 (2018) reconoce líneas con una red LSTM, pero sigue necesitando texto limpio y horizontal.

Limitaciones comunes:

- Falla con texto curvo, distorsionado o en perspectivas inusuales.
- Poca robustez ante fuentes manuscritas complejas o variaciones tipográficas.
- Sensible al ruido de fondo, baja resolución o iluminación deficiente.
- Requiere preprocesamiento intensivo (normalización, binarización).

El presente: transformers para OCR (TrOCR y VLM)

Arquitectura end-to-end: utiliza Vision Transformers (ViT) para codificar la imagen de forma global y un decoder de texto (en TrOCR, inicializado desde RoBERTa) genera la secuencia de caracteres.

Lo que cambia: lee la línea entera de una vez, con el contexto de las letras vecinas, en lugar de reconocer caracteres sueltos.

Estado del arte (SOTA):

- **TrOCR (Microsoft):** un referente específico para tareas de OCR.
- **Qwen3-VL y Qwen3.5:** VLM que leen y además razonan sobre el texto, por ejemplo devolviendo en JSON los campos de una factura.

Herramientas de OCR

EasyOCR, TrOCR y VLM.

EasyOCR

Es ligera, soporta más de 80 idiomas y funciona eficientemente en CPU. Ideal para prototipos rápidos y escenarios donde no se dispone de GPU.

TrOCR (Hugging Face)

Muy preciso en texto impreso y en manuscrito, según la variante. Lee una sola línea ya recortada, así que necesita un detector de texto delante. Va mucho mejor con GPU.

VLM (Qwen, Gemini, GPT): documentos estructurados

Para facturas, tablas y formularios. Devuelven los datos ya ordenados, por ejemplo en JSON, en lugar de texto suelto, y pueden razonar sobre lo que leen.

Salida de cada tipo de OCR

La misma foto de una placa, leída de tres formas. Cambia la herramienta y mira qué recibe tu programa.



Serigrafía de una placa real, con texto pequeño, girado por el brillo del cobre y mezclado con los componentes. Las cajas están medidas a mano para enseñar el formato de salida.

```
C1  C5  R6  C4  PULSE
T1  R3  MCP6004
IC2  R4  R11  R10  R5  R9
J1  VCC  EN  VOUT  GND
R1  R2  R7  R8
Place finger  SENSOR
Easy Pulse
www.Embedded-Lab.com
```

Sale una tira de texto sin posiciones: ves «R1 R2 R7 R8», pero no sabes qué resistencia es cada una ni dónde está en la placa.

> La pregunta útil es qué necesita tu programa, más que qué herramienta lee mejor. Para contar si la serigrafía está impresa basta la primera; para comprobar que cada referencia está junto a su componente hacen falta coordenadas; para rellenar un parte de recepción con el modelo y el fabricante, el VLM devuelve directamente los campos que necesitas.

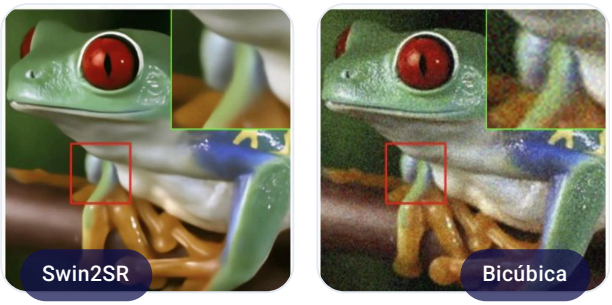
Las cajas de esta pantalla están medidas a mano sobre la foto para ilustrar el formato de salida, no las ha producido un OCR. Tres cosas que se ven en esta imagen y que aparecen en cualquier planta: el texto de la serigrafía es de bajo contraste sobre verde y el brillo del cobre lo rompe, hay texto a distintas escalas en la misma foto, y varias referencias quedan parcialmente tapadas por los componentes. Por eso la resolución de captura manda más que el modelo: con menos de veinte píxeles de altura por carácter, ningún OCR actual lee de forma fiable. Sobre latencia y coste, Tesseract corre en CPU en decenas de milisegundos, un modelo de detección más reconocimiento ronda las décimas de segundo en GPU, y un VLM se va a varios segundos por imagen, así que en línea suele combinarse: detección rápida siempre y VLM solo sobre las piezas dudosas.

Superresolución: ampliar una imagen

Ampliar una imagen generando el detalle que falta, con mejor resultado que la interpolación bicúbica.

El modelo del cuaderno: Swin2SR (2022).

- Basado en Swin Transformers V2, lo que le permite procesar imágenes de manera eficiente y global.
- La familia tiene versiones para ampliar y otras para quitar los artefactos de la compresión JPEG; el cuaderno usa la de ampliar ×2.
- **Lo que aporta:** recupera y sintetiza texturas finas (como pelo, tela o detalles faciales) que los métodos clásicos dejarían borrosas o artificiales.



Mira el recuadro rojo: la textura fina de la derecha la sintetiza el modelo.

> **Ojo:** el modelo «imagina» detalles a partir de los patrones que vio al entrenar; no reconstruye información que nunca existió.

Usos y límites

Dónde se usa.

Restauración de archivos

- Digitalización de fotos antiguas o documentos históricos dañados.
- Mejora de contenido multimedia antiguo (remasterización).

Medicina e imagen satelital

- Mejorar la legibilidad de escáneres médicos.
- Zoom en imágenes aéreas o satelitales.

E-commerce y marketing

- Mejorar fotos de productos de baja calidad enviadas por usuarios o proveedores.
- Lograr una apariencia profesional en la web para el catálogo de productos.

Riesgo: el modelo puede inventar una mancha que no existe. En diagnóstico, siempre con revisión humana.

El detalle que añade el modelo

Lo que aparece al ampliar puede venir del modelo, no del sensor.

Una superresolución muestra una mancha nueva en una imagen médica. ¿Qué concluyes?

- A La mancha estaba en el original.
- B Hay que validarla contra el original y el proceso clínico.
- C Una mayor resolución siempre elimina el error.

Respuesta B. Exacto: la mejora visual no convierte el detalle generado en evidencia.

La superresolución sintetiza textura plausible a partir de patrones aprendidos. En un contexto diagnóstico, cualquier estructura nueva debe comprobarse sobre la imagen original.

Quitar el fondo

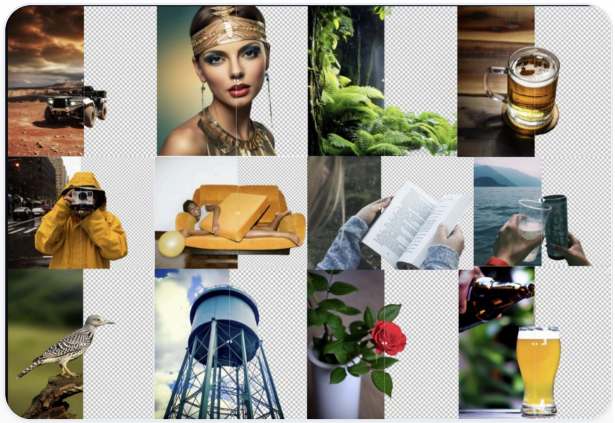
Lo difícil son los bordes: pelo, pelaje y cristal.

El problema: bordes difusos

Segmentar objetos sólidos es fácil. Pero elementos como el pelo, el pelaje o el vidrio transparente son extremadamente difíciles de separar debido a sus bordes difusos y semitransparentes.

La solución: RMBG-1.4 (BRIA AI)

Segmenta el objeto principal y devuelve una máscara con valores graduales en los bordes, que se usa como canal alfa en lugar de una máscara binaria, así que el recorte encaja en cualquier fondo sin efecto «pegatina». Su licencia no permite uso comercial sin acuerdo con BRIA.



Correspondencias entre imágenes (matching)

Métodos para encontrar el mismo punto en dos imágenes.

¿Qué es? Encontrar puntos idénticos en dos fotos de la misma escena tomadas desde ángulos diferentes, a pesar de cambios en la perspectiva o la iluminación. Es la base de la reconstrucción 3D, la realidad aumentada y la localización de robots.

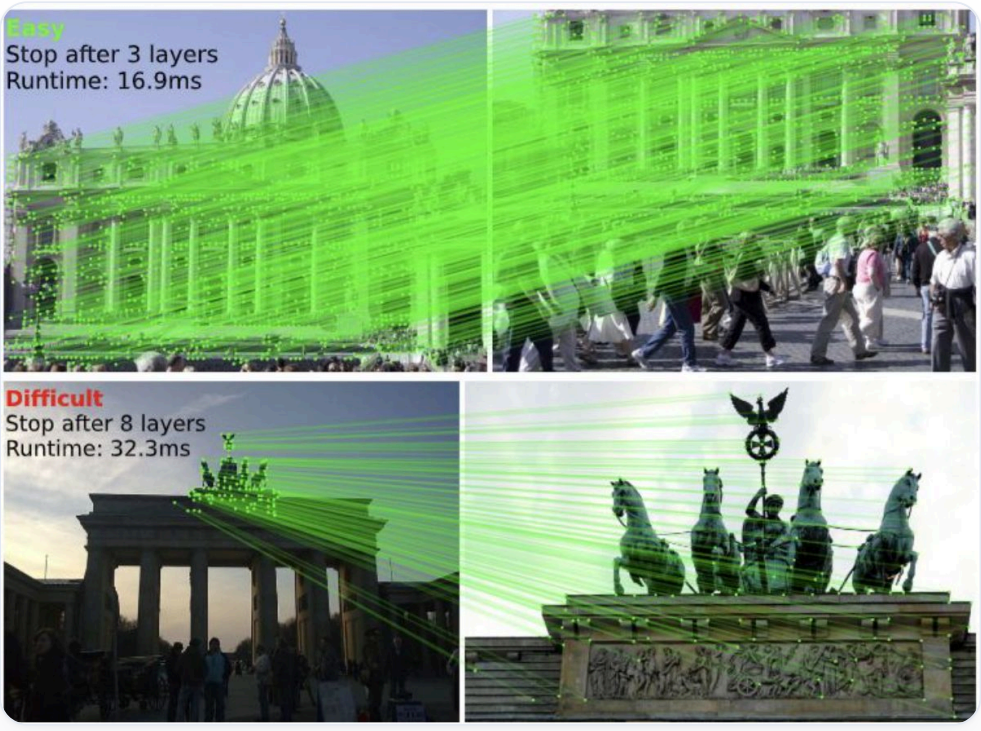
La nueva era: deep learning

Detector (SuperPoint, DISK)

Una red que localiza los puntos más distintivos de la imagen (esquinas, texturas) y describe cada uno con un vector. Aguanta mejor que SIFT los cambios fuertes de luz y de punto de vista.

Matcher (LightGlue)

Un Transformer que compara los puntos de las dos imágenes, decide cuáles se corresponden y descarta los que no tienen pareja. Los errores geométricos que se le escapan se filtran después comprobando la geometría (RANSAC).



Dónde se nota: con cambios de luz (de día a noche), grandes variaciones de perspectiva y oclusiones, justo donde los métodos clásicos fallan más.

Para qué sirve el matching

Tres usos habituales.

Fotogrametría (SfM)

Al identificar y conectar puntos coincidentes en múltiples fotos de una escena, se puede reconstruir la geometría 3D del objeto y la posición de la cámara en cada toma.

Panoramas (stitching)

Permite fusionar sin problemas varias imágenes superpuestas en una única foto de gran formato o una vista de 360 grados, eliminando duplicados y alineando las perspectivas.

SLAM (robótica)

Un robot utiliza el matching de características para comprender su posición dentro de un entorno y construir un mapa del mismo, incluso mientras se mueve y explora.

Profundidad desde una sola foto

Qué está cerca y qué está lejos, con una cámara normal.

Depth Anything V2/V3

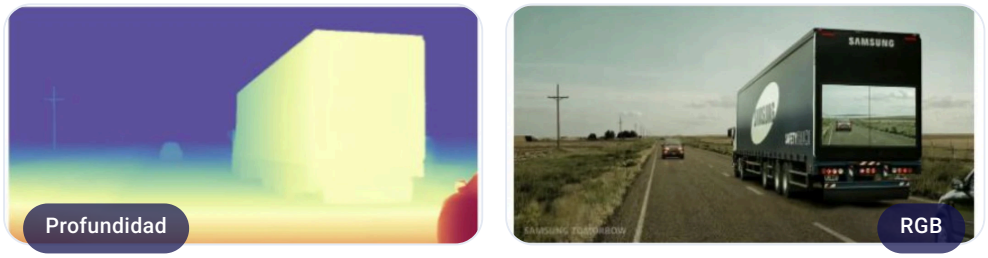
Un modelo fundacional con encoder DINOv2. La V2 se entrenó con 595.000 imágenes sintéticas etiquetadas y 62 millones de imágenes reales con pseudoetiquetas.

Capacidad

Genera un mapa de profundidad (heatmap) donde el color indica la distancia relativa, revelando la estructura 3D subyacente.

Robustez

Aguanta interiores, exteriores y escenas con mucho detalle. Cristales y espejos, que hacían fallar a la V1, los maneja mucho mejor gracias a los datos sintéticos; aun así, compruébalo con tus imágenes.



Una sola cámara y una sola imagen: el modelo deduce qué está cerca y qué está lejos.

Recortar una foto por distancia

El mapa de profundidad de la pantalla anterior, usado como filtro: todo lo que queda más lejos que el corte se aclara. No hacen falta clases ni etiquetas: basta un umbral sobre la cercanía.

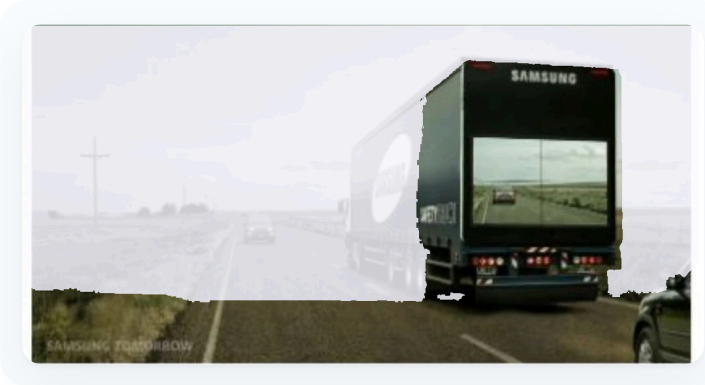


Imagen que se conserva

42 %

Queda la trasera del camión, y la pantalla que muestra otra carretera sigue entera: el modelo le da la distancia del camión aunque enseñe una carretera lejana.

Mapa precalculado, el de la pantalla anterior; el corte se aplica en tu navegador. La escala es relativa: 100 no equivale a ninguna distancia en metros.

Esta página recoge el corte en 100 de 255, que conserva el 42 % de la imagen: la trasera del camión, el asfalto cercano y el coche de la derecha. El costado del camión se aleja de la cámara y queda fuera. La pantalla trasera, que muestra la carretera de delante, se conserva entera porque el modelo mide a qué distancia está la superficie de la pantalla; la carretera que aparece en ella no cuenta. Con el corte en 30 solo desaparece el cielo; desde 130 el camión entero queda al otro lado.

Aplicaciones de la profundidad

¿Para qué sirve un mapa de profundidad?

Efecto retrato (bokeh)

Desenfocar el fondo sintéticamente, creando imágenes con una profundidad de campo profesional y destacando el sujeto principal.

Robótica y navegación

Permitir que robots y vehículos autónomos detecten obstáculos y comprendan su entorno 3D, utilizando solo una cámara de bajo coste.

Generación de nubes de puntos

Convertir una foto plana en una estructura 3D navegable (malla o nube de puntos) al combinar la imagen RGB con su mapa de profundidad.

Recorte por distancia

Un umbral sobre el mapa elimina lo que queda más lejos (o más cerca) de lo que interesa, sin clases ni etiquetas.

Profundidad relativa vs. métrica. Estos modelos suelen estimar profundidad relativa (mapas de calor). Para obtener metros reales se necesita calibración de cámara o un modelo de profundidad métrica; Depth Anything V2 tiene variantes métricas para interior y exterior.

Profundidad relativa o en metros

Un mapa normalizado ordena distancias, pero no las mide.

Necesitas saber si un obstáculo está a 1,5 metros. ¿Te basta un mapa de profundidad relativa?

- A Sí: el color ya indica los metros.
- B Sí, si la imagen tiene buena resolución.
- C No: hace falta un modelo métrico o una referencia de tamaño conocido.

Respuesta C. Exacto: un mapa relativo ordena distancias, pero no las mide.

Un mapa relativo dice qué está más cerca que qué. Para responder «a cuántos metros» hacen falta calibración de cámara, una referencia conocida o un modelo entrenado para profundidad métrica.

Casos por sector

Los mismos modelos, combinados de otra manera, resuelven problemas muy distintos. Lo que cambia de un sector a otro es qué hay que vigilar.

Vigilancia y seguridad

Detectar y seguir personas y vehículos, contar los que entran en una zona, avisar de una caída con la pose. RF-DETR con un seguidor (tema 1) y ViTPose (este tema).

Ojo: el Reglamento europeo de IA prohíbe desde febrero de 2025, salvo excepciones tasadas, la identificación biométrica remota en tiempo real en espacios públicos con fines policiales y el reconocimiento de emociones en el trabajo.

Industria

Defectos sin ejemplos de defecto, conteo de piezas, lectura de lotes y etiquetas, medidas con máscaras. DINOv3 con banco de normalidad (tema 4), SAM (tema 5) y OCR (este tema).

Ojo: luz y encuadre estables, y un umbral fijado con piezas buenas.

Robótica

Saber qué está cerca con una sola cámara, recortar el objeto que hay que coger, encontrar objetos nuevos por su nombre. Depth Anything (este tema), SAM 2 (tema 5) y Grounding DINO (tema 3).

Ojo: esta profundidad es relativa; para coger un objeto hacen falta metros.

Automoción

Vehículos, peatones y señales, la calzada separada del resto, distancias y matrículas. Detectores en tiempo real (tema 1), segmentación (tema 5), profundidad y OCR (este tema).

Ojo: tiempo real en el hardware del coche, y noche, lluvia y contraluz en los datos de validación.

Las prohibiciones del artículo 5 del Reglamento (UE) 2024/1689 se aplican desde el 2 de febrero de 2025. Entre ellas están la identificación biométrica remota en tiempo real en espacios de acceso público con fines policiales, salvo excepciones tasadas, y el reconocimiento de emociones en el lugar de trabajo y en centros educativos, salvo por motivos médicos o de seguridad. Contar personas sin identificarlas no entra en esas prohibiciones, pero sigue sujeto al RGPD. Para la profundidad métrica hace falta un modelo entrenado para ello, una cámara estéreo o calibración.

Antes de usar cualquiera de estas seis

Seis comprobaciones comunes a tareas muy distintas.

- [ ] **Sabes qué es medida y qué es generación**
  Pose y profundidad estiman; superresolución sintetiza. No se usan igual como evidencia.
- [ ] **La licencia permite tu uso**
  Varias de estas familias tienen restricciones comerciales. Compruébalo por modelo.
- [ ] **La escala está resuelta**
  Si necesitas metros, un mapa relativo no sirve: hace falta calibración o un modelo métrico.
- [ ] **Probado con tus imágenes**
  Resolución, encuadre y calidad reales, no las fotos de la demo.
- [ ] **Sin diagnóstico automático**
  En medicina o seguridad, revisión humana sobre la imagen original.
- [ ] **Coste por imagen calculado**
  Si vas a procesar miles, mide tiempo y memoria antes de comprometerte.

Cuaderno 6: otras tareas

Los ejercicios están en el cuaderno. El extra, si da tiempo, lo hacemos juntos; si no, queda para casa.

1. Pose y medir un ángulo
2. OCR
3. Superresolución
4. Quitar el fondo
5. Profundidad con una sola foto
6. Extra: el otro codo y una etiqueta propia
7. Para casa: combinar dos tareas

Abrir en Colab ↗

En Colab: Archivo, Guardar una copia en Drive, y Entorno de ejecución, GPU T4.