


De píxeles a significado

Una imagen empieza como números. La tarea decide qué información buscamos.

Human Vision VS Computer Vision



El modelo conecta patrones visuales con una salida útil.

Las imágenes digitales son matrices de píxeles. La visión artificial aprende representaciones que permiten asociar esos valores con objetos, relaciones o regiones.

¿Qué salida necesitas?

La misma imagen admite tareas distintas.



Quieres contar coches y localizar cada uno.


-
- ☐ **A** Una etiqueta para toda la imagen.
-
- ☐ **B** Una caja y una categoría por objeto.
-
- ☐ **C** Una puntuación de confianza para la imagen.
-

Respuesta B. Exacto: la detección localiza cada instancia y permite contarla.

La clasificación da una etiqueta global. La detección devuelve cajas y categorías por instancia. La segmentación delimita píxeles. Otros problemas incluyen anomalías, pose, OCR, profundidad y superresolución.

Detectar es localizar

Cada detección combina una caja, una categoría y una puntuación.




Caja · categoría · puntuación de confianza

La puntuación ordena las predicciones según el modelo. No equivale automáticamente a una probabilidad calibrada y no dice por sí sola si la caja está bien situada.

Tres familias de detectores

Dos etapas, una etapa y detectores con transformer organizan el problema de formas diferentes.




El árbol sirve como mapa. Nos centraremos en las ideas que separan las familias.

Las taxonomías cambian con el tiempo y hay modelos híbridos. Esta clasificación ayuda a situar los ejemplos del tema, no a decidir qué detector es mejor sin medirlo.

Cómo cambió el recorrido


La evolución redujo pasos intermedios y cambió la forma de asignar predicciones.



Una familia explica el flujo de cálculo, no una garantía de precisión o velocidad.

Patrones, capa a capa


Las convoluciones extraen rasgos locales que capas posteriores combinan.



Las CNN incorporan localidad e invariancia aproximada a traslaciones. Siguen siendo componentes útiles en muchos detectores; el contexto global y la atención son decisiones de arquitectura, no una carencia universal de todas las CNN.

Primero regiones, después clases

Los detectores de dos etapas refinan candidatos antes de decidir qué objeto contienen.



La propuesta de región reduce dónde debe mirar el clasificador.

R-CNN, Fast R-CNN y Faster R-CNN son hitos de esta familia. Las cifras de velocidad dependen de implementación, datos y hardware, así que una tabla histórica no basta para elegir un detector hoy.

Eliminar trabajo repetido


Cada cambio de diseño buscó compartir más cálculo entre las regiones de una imagen.

Results			
	RCNN	Fast RCNN	Faster RCNN
Proposal Generation Method	Selective Search	Selective Search	RPN
Proposal Generation Time	1500 ms	1500 ms	10 ms
Predictions for Generated Proposals Time / Image	47000 ms	320 ms	190 ms
Speedup Factor	X	25X	250X

Comparación histórica: los tiempos solo se interpretan con su hardware y protocolo originales.


Una propuesta se convierte en candidato

R-CNN ilustra el recorrido de una región desde la imagen hasta la clase.



Una pasada, muchas predicciones

YOLOv1 popularizó la idea de producir cajas y clases directamente desde la imagen.



¿Qué describe la idea de un detector de una etapa?


- ☐ A Propone regiones y las clasifica en un segundo recorrido.
- ☐ B No necesita imágenes de entrenamiento.
- ☐ C Predice localización y categoría en una misma ruta de detección.

Respuesta C. Exacto: esa es la idea central, aunque los detalles cambian entre versiones.

La cuadrícula S×S es una explicación histórica de YOLOv1. Las variantes posteriores cambiaron detalles importantes, por lo que no debe describirse toda la familia moderna con ese único diagrama.

La cuadrícula de YOLOv1

En la formulación original, una celda responde por objetos cuyo centro cae en ella.



Esquema histórico de YOLOv1, no una descripción de todas las versiones posteriores.

De la imagen a las cajas


La red comparte representación visual antes de producir localizaciones y categorías.

In summary

SCHEME



ARCHITECTURE



LOSS FUNCTION

$$L = \sum_{i=0}^{S^2} \mathbb{I}_i^{\text{obj}} \sum_{c \in \text{classes}} (p_i(c) - \hat{p}_i(c))^2 + \lambda_{\text{coord}} \sum_{i=0}^{S^2} \sum_{j=0}^B \mathbb{I}_{ij}^{\text{obj}} (\sqrt{w_i} - \sqrt{\hat{w}_i})^2 + (\sqrt{h_i} - \sqrt{\hat{h}_i})^2$$

$$+ \lambda_{\text{coord}} \sum_{i=0}^{S^2} \sum_{j=0}^B \mathbb{I}_{ij}^{\text{obj}} (x_i - \hat{x}_i)^2 + (y_i - \hat{y}_i)^2 + \lambda_{\text{noobj}} \sum_{i=0}^{S^2} \sum_{j=0}^B [\mathbb{I}_{ij}^{\text{noobj}} (C_i - \hat{C}_i)^2] + \sum_{i=0}^{S^2} \sum_{j=0}^B [\mathbb{I}_{ij}^{\text{obj}} (C_i - \hat{C}_i)^2]$$

Arquitectura de YOLOv1: un referente histórico para entender el enfoque de una etapa.

La familia siguió cambiando


«YOLO» nombra una línea de trabajo, no una arquitectura fija.



Las comparativas entre generaciones no deben tratar una versión, una implementación o un checkpoint como representante automático de toda una familia.

Localidad y contexto global

Una arquitectura decide cómo combina información cercana y relaciones lejanas.



La atención ofrece una forma de relacionar partes separadas de una imagen.

Consultas para objetos

DETR predice un conjunto de candidatos a partir de características visuales y consultas aprendidas.





Fig. 2: DETR uses a conventional CNN backbone to learn a 2D representation of an input image. The model flattens it and supplements it with a positional encoding before passing it into a transformer encoder. A transformer decoder then takes as input a small fixed number of learned positional embeddings, which we call *object queries*, and additionally attends to the encoder output. We pass each output embedding of the decoder to a shared feed forward network (FFN) that predicts either a detection (class and bounding box) or a “no object” class.

Una consulta puede acabar asociada a una caja y una clase.

El diseño original utiliza un encoder y un decoder transformer. Los detalles concretos, como número de consultas o backbone, pertenecen a una versión específica.

Asignar antes de aprender

Durante el entrenamiento, DETR relaciona predicciones y objetos reales uno a uno.



¿Para qué sirve la asignación bipartita en DETR durante el entrenamiento?


-
- ☐ **A** Relacionar predicciones y objetos reales uno a uno al calcular la pérdida.
-
- ☐ **B** Aplicar NMS a las cajas de cada imagen al predecir.
-
- ☐ **C** Crear automáticamente etiquetas para entrenar.
-

Respuesta A. Exacto: define qué objetivo supervisa cada predicción.

La asignación bipartita define objetivos para calcular la pérdida durante entrenamiento. No es el mismo proceso que aplicar supresión de no máximos durante inferencia.

El detector de la práctica


RF-DETR es el ejemplo que usaremos para ejecutar inferencia en el cuaderno.



La arquitectura exacta depende de la variante y del checkpoint del notebook. La práctica debe describir el modelo que realmente carga, no inferir todos los detalles a partir de DETR original.

Elegir requiere condiciones

Calidad, latencia, licencia y mantenimiento solo se comparan con versión, datos y hardware explícitos.



Una gráfica tiene sentido solo con su protocolo de medida y versiones concretas.

RF-DETR es la elección docente de este curso. Eso no demuestra que sea el mejor detector para cada producto: la decisión requiere una evaluación en el dominio, condiciones de despliegue y revisión de licencias de la versión concreta.

¿Cuánto coinciden las cajas?

$\text{IoU} = \text{área compartida} \div \text{área total ocupada}.$

Referencia



Predicción

IoU

0.33

Solapamiento parcial.

IoU vale 1 cuando ambas cajas coinciden y 0 cuando no comparten área. Para decidir TP, FP y FN también se tiene en cuenta la clase, la correspondencia uno a uno y un protocolo de evaluación.

Contar aciertos y fallos


Una predicción puede acertar, duplicar un objeto o dejar un objeto sin detectar.

TP Caja y clase que corresponden a un objeto real.	FP Falsa alarma o predicción duplicada.	FN Objeto real que quedó sin predicción.
--	---	--

En detección no se suele usar un recuento práctico de verdaderos negativos de fondo. Las ubicaciones sin objetos son enormes y no se enumeran como predicciones negativas individuales.

Precisión y recall responden a preguntas distintas

La precisión mira las predicciones; el recall mira los objetos reales.



$$\text{Precisión} = \frac{TP}{(TP + FP)}. \text{ Recall} = \frac{TP}{(TP + FN)}.$$


Hay 3 TP, 1 FP y 2 FN. ¿Cuáles son precisión y recall?

- ☐ A Precisión 0,60; recall 0,75.
- ☐ B Precisión 0,75; recall 0,75.
- ☐ C Precisión 0,75; recall 0,60.

Respuesta C. Exacto: $3/(3+1)$ y $3/(3+2)$.

Filtrar no cambia las cajas

El umbral de confianza decide qué predicciones se muestran; IoU evalúa su solapamiento.




Subes el umbral de confianza y mantienes fijas las predicciones candidatas.

- ☐ **A** Se conservan las mismas o menos cajas.
- ☐ **B** Aparecen categorías nuevas.
- ☐ **C** Aumenta necesariamente la IoU de todas las cajas restantes.

Respuesta A. Exacto: el filtro elimina las puntuaciones que quedan por debajo del nuevo umbral.

Una curva resume umbrales


AP resume precisión y recall al recorrer puntuaciones. mAP agrega AP según un protocolo.



AP50 y AP promediada entre varios umbrales IoU responden a protocolos distintos.

El vocabulario depende de los datos

Un checkpoint aprende las clases de sus datos. Tu aplicación puede necesitar otras.



Tu checkpoint solo conoce clases COCO y necesitas detectar un defecto industrial nuevo.

-
- ☐ A Bajar mucho el umbral para crear la categoría.
-
- ☐ B Evaluar adaptación con datos etiquetados o un modelo adecuado al nuevo vocabulario.
-
- ☐ C Aumentar el tamaño de las cajas existentes.
-

Respuesta B. Exacto: la nueva categoría exige una estrategia y una evaluación en el dominio.

Mide donde vas a usarlo

Un benchmark no sustituye datos representativos, latencia medida y análisis de errores.

Datos que representen escenas, clases y condiciones reales.

Latencia medida en el sistema de destino.

Errores revisados: falsas alarmas, objetos omitidos y casos límite.

Un detector logra mejor AP en un benchmark publicado. ¿Basta para elegirlo?

- ☐ **A** Sí, cualquier mejora de AP garantiza mejor producción.
-
- ☐ **B** Sí, si es el modelo más reciente.
-
- ☐ **C** No: hay que medir calidad y latencia con datos y condiciones representativos.
-

Respuesta C. Exacto: la elección depende del problema, del entorno y de los errores que aceptas.

Ahora, con tu propia imagen

Prueba RF-DETR en tu copia del cuaderno.

1. Guarda una copia en Drive.
2. Ejecuta el detector con una imagen.
3. Cambia el umbral de confianza: $0,25 \cdot 0,50 \cdot 0,75$.

[Abrir en Colab](#) ↗

En Colab: Archivo → Guardar una copia en Drive. Empieza por inferencia. La disponibilidad de GPU varía; el entrenamiento necesita además el dataset indicado en el notebook.