

## 2. El ecosistema de modelos de IA

Buscar, evaluar licencias y usar modelos fácilmente.

Hugging Face se ha convertido en el **repositorio central de facto** para modelos de IA modernos, datasets, demos interactivas y herramientas de desarrollo. Su ecosistema integrado permite descubrir, probar y desplegar modelos.



**Hugging Face**

# El ecosistema Hugging Face

Hugging Face no es solo un repositorio, es un **ecosistema completo de cuatro pilares interconectados**.

## Model Hub

Catálogo con más de 500.000 modelos preentrenados para todas las tareas imaginables: visión, NLP, audio, multimodal.

## Datasets

Más de 100.000 datasets públicos listos para entrenar y evaluar, con APIs unificadas de carga y procesamiento.

## Spaces

Demos web interactivas con Gradio o Streamlit, desplegadas sin servidor. Prueba modelos en segundos con interfaz gráfica.

## Transformers

Librería Python que unifica la API de carga, inferencia y fine-tuning para miles de arquitecturas diferentes.


## El flujo típico

01 Buscar modelo

02 Probar en Space

03 Descargar con Transformers

04 Integrar en tu aplicación



[huggingface.co/models](https://huggingface.co/models)

# Cómo buscar modelos efectivamente

El Model Hub permite **filtrar por múltiples criterios** para encontrar exactamente lo que necesitas:

- **Tarea:** object-detection, image-classification, text-generation, etc.
- **Licencia:** Apache-2.0, MIT, CreativeML, Research-only.
- **Popularidad:** número de descargas, likes, fecha de última actualización.

La **Model Card** es tu mejor amiga. Cada modelo debe incluir:

## Descripción y uso

Para qué fue entrenado, qué tareas resuelve, cómo usarlo con código de ejemplo.

## Limitaciones

Sesgos conocidos, casos donde falla, advertencias de seguridad y aspectos éticos.

## Licencia

Términos legales de uso: ¿puedes usarlo comercialmente? ¿Debes atribuir autoría?

## Archivos

Configuración JSON, pesos del modelo (.safetensors preferido), tokenizers, ejemplos.

## Métricas

Resultados en benchmarks estándar, comparación con otros modelos.

Las descargas y los likes sirven para descubrir candidatos, no para decidir cuál funciona mejor en tu dominio. La fecha de última actualización avisa de modelos abandonados.

# Antes de descargar, lee la ficha

La Model Card contesta si el modelo sirve para tu caso antes de gastar tiempo.

**Buscas un clasificador para imágenes médicas. ¿Qué debes hacer primero?**

- ☐ A Elegir el modelo con más descargas.
- ☐ B Filtrar por tarea y revisar la model card con el dominio y licencia en mente.
- ☐ C Descargar todos los modelos y comparar solo su tamaño.

Respuesta B. Exacto: la tarea reduce la búsqueda y la documentación permite juzgar la adecuación.

Un dominio sensible obliga a revisar para qué se entrenó el modelo, con qué datos y qué limitaciones declara. El número de descargas no responde a ninguna de esas preguntas.

# Licencias: evita problemas legales

La licencia del modelo determina **cómo puedes usarlo legalmente**. Ignorar este aspecto puede causar problemas serios en producción.

## Comercial OK

- **Apache-2.0**: muy permisiva, ideal para empresas.
- **MIT**: similar a Apache, aún más simple.
- **BSD**: variantes 2-clause y 3-clause, ambas permisivas.

## Con restricciones

- **OpenRAIL/CreativeML**: uso comercial OK, pero con cláusulas de uso responsable.
- **CC BY-SA**: requiere compartir derivados bajo la misma licencia.

## No comercial

- **Research Only**: solo investigación académica.
- **CC BY-NC**: prohibido uso comercial.

**Caso especial AGPL**: algunas familias YOLO populares usan AGPL, que **obliga a publicar tu código fuente completo** si integras el modelo en una aplicación web o servicio. Si no quieres publicar tu código, busca alternativas con Apache-2.0 como RT-DETR o RF-DETR.

Las condiciones se revisan por artefacto y por versión: el repositorio de código y los pesos publicados pueden llevar licencias distintas, y ambas pueden cambiar entre versiones. Esta clasificación orienta la búsqueda; la decisión final se toma leyendo la licencia vigente del artefacto concreto.

# Comprueba licencia y caso de uso

La misma licencia cambia de respuesta según lo que vayas a hacer con el modelo.

AGPL



Servicio web o SaaS



## Permitido con condiciones

La cláusula de red obliga a publicar tu código fuente completo aunque solo lo ofrezcas por web. Alternativas Apache-2.0: RT-DETR o RF-DETR.

Orientación para buscar, no asesoramiento legal. La licencia real se lee en el artefacto y la versión que vayas a usar.

La tabla recoge lo que explica la diapositiva anterior. Los tres casos que más sorprenden: AGPL no obliga a nada mientras no distribuyas ni sirvas el modelo, pero sí en cuanto lo expones por web; una licencia no comercial tampoco vale para un prototipo interno de empresa, porque el propósito ya es comercial; y CC BY-SA permite vender, pero obliga a publicar los derivados con la misma licencia.

# Código y pesos pueden diferir

Un repositorio permisivo no garantiza que los pesos lo sean.

Un repositorio tiene código permisivo, pero los pesos incluyen otra licencia. ¿Qué debes revisar?

- ☐ A Solo la licencia del código.
- ☐ B Las condiciones de código, pesos, datos y uso de la versión concreta.
- ☐ C Nada si el modelo se puede descargar sin pagar.

Respuesta B. Exacto: cada recurso puede añadir términos distintos.

Conviene revisar la licencia del repositorio, la del checkpoint concreto y la de los datos de entrenamiento cuando se declara, además de la versión a la que se aplican.

# Usar modelos

La librería Transformers hace que cargar y usar modelos sea **muy sencillo**. El modelo mental clave:

## 01 Hub remoto

El modelo vive en Hugging Face Hub identificado por su nombre (ej: «facebook/detr-resnet-50»).

## 02 Descarga a caché

Primera ejecución: descarga config.json, pesos .safetensors, y metadatos a ~/.cache/huggingface/

## 03 Carga en memoria

El modelo se instancia en RAM/VRAM según el dispositivo (CPU/GPU) que especifiques.

## 04 Inferencia

Procesas inputs y obtienes predicciones. Puedes usar GPU y mixed precision para acelerar.

## Buenas prácticas

- **Seguridad:** prefiere .safetensors sobre .bin (formato más seguro).
- **Offline:** predescarga con snapshot\_download, controla cache\_dir.
- **Rendimiento:** usa float16 y device="cuda" cuando tengas GPU.
- **Pipelines:** para pruebas rápidas, usa pipeline("task"); en producción, clases específicas dan más control.

# Inferencia en 3 líneas de código

```
from transformers import pipeline

# 1. Cargar modelo (automáticamente baja config y pesos)
detector = pipeline("object-detection", model="facebook/rt-detr-l")

# 2. Inferencia
results = detector("imagen.jpg")

# 3. Resultado
print(results) # [{'label': 'cat', 'score': 0.99, 'box': {...}]}
```

La librería **transformers** maneja la descarga, el pre-procesamiento y la inferencia automáticamente.

El identificador del modelo determina qué arquitectura y qué preprocesador se instancian. Para reproducibilidad conviene fijar también la revisión. En producción, las clases específicas permiten controlar batching, dispositivo, precisión y formato de salida.

# Qué te ahorra un pipeline

Conviene saber qué pasos quedan ocultos antes de llevarlo a producción.

¿Qué simplifica un pipeline de Transformers?

- ☐ A La preparación de entrada y la ejecución de una tarea común.
- ☐ B La necesidad de conocer la licencia y la model card.
- ☐ C El entrenamiento de cualquier modelo sin datos.

Respuesta A. Exacto: el pipeline agrupa pasos frecuentes para una primera prueba.

El pipeline reúne preprocesado, inferencia y posprocesado para una tarea común. No elige el modelo por ti ni garantiza el mejor rendimiento en tu dominio.

# Busca y prueba un modelo

Compara la documentación con lo que observas al ejecutar el cuaderno.

1. Guarda una copia en Drive.
2. Ejecuta el modelo propuesto.
3. Elige otro y justifica la decisión.

Abrir en Colab ↗

Para que la comparación sea reproducible, anota el identificador y la revisión del modelo, la tarea, la licencia, el preprocesador, el dispositivo y el consumo aproximado de memoria. Las descargas o likes sirven para descubrir candidatos, no para decidir cuál funciona mejor en tu dominio.