

5. SAM: Segment Anything (v1, v2, v3)

Segmentación universal en imagen y vídeo, con prompts.

SAM (Segment Anything Model) es la evolución del modelo de segmentación más versátil: segmenta cualquier objeto en cualquier imagen mediante prompts simples (puntos, cajas, máscaras), y mantiene coherencia temporal en vídeo sin entrenar para clases específicas.



¿Qué es segmentación?

La segmentación de imágenes es una tarea básica en visión artificial que va más allá de la simple detección. Su objetivo es asignar una etiqueta de clase a cada píxel de una imagen, delimitando el contorno exacto de los objetos y el fondo.

Tipos de segmentación

Semántica

Cada píxel se clasifica en una categoría (por ejemplo, «coche», «persona», «fondo»). No distingue entre instancias individuales del mismo tipo de objeto: todos los coches reciben la misma máscara y etiqueta.

Por instancias


Cada objeto individual detectado recibe una máscara única y su propia etiqueta. Permite distinguir entre objetos del mismo tipo, como «coche 1», «coche 2», «persona A», «persona B».

Panóptica

Combina la segmentación semántica y por instancias. Asigna una máscara única y una etiqueta a cada instancia de objeto cubriendo toda la imagen. Es la más completa pero también la más compleja.



(a) Image



(b) Semantic Segmentation



(c) Instance Segmentation



(d) Panoptic Segmentation

Arquitectura de SAM 1

Un diseño eficiente basado en tres componentes desacoplados.

Image encoder (el componente pesado)


- Basado en Vision Transformer (ViT-H) preentrenado con MAE.
- Se ejecuta una única vez por imagen, generando un embedding reutilizable.
- Costoso computacionalmente, pero desacoplado de la interacción.

Prompt encoder (el componente ligero)

- Codifica entradas en tiempo real: puntos, cajas y texto (con positional encodings).
- También procesa máscaras previas (con convoluciones).
- Convierte la intención del usuario en embeddings compatibles.

Mask decoder (el cerebro rápido)

- Arquitectura Transformer ligera (two-way transformer).
- Realiza cross-attention entre embeddings de imagen y prompts.
- Predice 3 máscaras de salida (whole, part, subpart) para resolver ambigüedad.
- Latencia muy baja (unos 50 ms en navegador web).



SAM 1 admite puntos, cajas y máscaras de forma nativa. El texto como prompt requiere un modelo externo, por ejemplo Grounding DINO o CLIP, que traduzca la frase a una indicación espacial.

Arquitectura de SAM 2

Unificando imágenes y vídeo con memoria temporal.

Encoder jerárquico (Hiera): la evolución


- Sustituye al ViT plano de SAM 1 por una arquitectura jerárquica (Hiera), un enfoque más potente.
- Procesa imágenes en múltiples escalas, capturando detalles finos y contexto global de forma simultánea.
- Mucho más eficiente, permitiendo el procesamiento de vídeo en tiempo real (streaming processing).
- Calcula los features del fotograma una sola vez, optimizando el rendimiento.

Mecanismo de memoria: la revolución

- Componente clave que permite entender el vídeo y mantener la coherencia temporal.
- **Memory bank:** almacena información de fotogramas pasados y del fotograma inicial (el prompt).
- **Memory attention:** permite al modelo «mirar atrás» para mantener la identidad del objeto a lo largo del tiempo.
- Maneja oclusiones, recordando el objeto incluso si desaparece momentáneamente de la vista.

Decodificador de máscaras y prompting: la interacción

- Recibe tanto los prompts del usuario (clics, cajas) como el contexto proporcionado por la memoria.
- Predice máscaras para el fotograma actual y actualiza la memoria para futuros procesamientos.
- **Ambiguity-aware:** genera 3 opciones de máscara si hay ambigüedad en la segmentación.
- Capaz de corregir la segmentación de todo el vídeo con una única corrección en un solo fotograma (propagación).



Arquitectura de SAM 3

Unificación de detección y tracking con desacoplamiento de reconocimiento.

Backbone unificado y prompting multimodal


- Utiliza un Perception Encoder (PE) compartido, preentrenado con alineación visión-lenguaje (contrastive learning).
- **Nuevos prompts:** acepta texto (frases nominales como «un gato rayado») e image exemplars (ejemplos visuales positivos o negativos).
- **Fusion encoder:** un nuevo módulo que condiciona los embeddings de imagen con los tokens del prompt antes de la decodificación.

Diseño dual: detector y tracker

- **Detector (DETR-based):** procesa cada frame independientemente para encontrar nuevos objetos que coincidan con el concepto.
- **Tracker (herencia de SAM 2):** utiliza el mecanismo de memoria para propagar identidades temporalmente.
- **Sinergia:** el detector alimenta al tracker con nuevos objetos; el tracker mantiene la coherencia temporal. Si el tracker falla, el detector puede reiniciarlo.

Innovación clave: el Presence Token

- Soluciona el conflicto entre reconocer («¿qué es?») y localizar («¿dónde está?»).
- Introduce un token global que predice la probabilidad de que el concepto exista en la imagen, $P(\text{presence})$.
- Las queries de objetos solo se enfocan en la localización condicional, $P(\text{match} | \text{presence})$.
- Resultado: reduce drásticamente los falsos positivos en vocabulario abierto al distinguir entre la existencia y la posición del objeto.



Evolución: SAM, SAM 2 y SAM 3

La familia de modelos Segment Anything (SAM) ha evolucionado rápidamente, ampliando sus capacidades de segmentación universal desde imágenes estáticas hasta el análisis complejo de vídeo con prompts contextuales.

01 2023 · SAM 1


Segmentación universal en imagen con prompts de puntos y cajas. Dataset SA-1B: unos 11 millones de imágenes y 1.100 millones de máscaras.

02 2024 · SAM 2

Extiende a vídeo con memoria en streaming; más preciso y hasta 6 veces más rápido que SAM 1 en imagen. Dataset SA-V: unos 51.000 vídeos y 643.000 masklets.

03 2025 · SAM 3

Modelo unificado que detecta, segmenta y sigue todas las instancias de un concepto, dado por texto o por ejemplos, en imagen y vídeo.



The data engine: cómo escalar a 1B de máscaras

La creación del dataset SA-1B, clave para el entrenamiento de SAM, se logró mediante un innovador proceso iterativo de «motor de datos», combinando la inteligencia humana con la capacidad de autoaprendizaje del modelo para escalar la anotación.

01 Anotación manual

Expertos humanos realizan anotaciones detalladas en un subconjunto inicial de imágenes. En esta fase, el modelo aún no tiene suficiente conocimiento.

02 Anotación semi-automática

El modelo, preentrenado con datos manuales, propone máscaras que los humanos revisan y corrigen. Esta interacción acelera el aprendizaje del modelo, que mejora exponencialmente.

03 Anotación totalmente automática

Una vez que el modelo es robusto, anota imágenes completas de forma autónoma. Solo se aceptan las máscaras con alta confianza, permitiendo un escalado masivo de datos.

Conclusión: SA-1B es 99,1 % generado automáticamente por el propio SAM, demostrando el poder del bucle de auto-mejora.

«Promptable segmentation»: la idea central

La segmentación promptable es la capacidad de un modelo de visión artificial para segmentar objetos en imágenes o vídeos basándose en diferentes tipos de prompts (indicaciones). Esto permite una interacción flexible y eficiente sin necesidad de reentrenar el modelo.

Tipos de prompts y sus capacidades

Puntos

- **Múltiples puntos:** incluye o excluye áreas específicas para refinar la máscara deseada.
- **Precisión:** útil para objetos ambiguos o con bordes complejos.

Cajas (bounding box)

- **Delimitación amplia:** dibuja una caja alrededor del objeto; SAM la convierte en una máscara precisa.
- **Rapidez:** ideal para segmentación rápida de objetos bien definidos.

Máscara inicial

- **Refinamiento:** proporciona una máscara aproximada (rough) y el modelo perfecciona los bordes y rellena huecos.
- **Perfeccionamiento:** útil para mejorar segmentaciones previas o manuales.

Texto

- **SAM 1 y SAM 2:** mediante adaptadores (CLIP o Grounding DINO), se puede usar texto como «el coche rojo».
- **SAM 3 (nativo):** interpreta directamente prompts de texto («el árbol de la izquierda») para generar máscaras.

Ejemplar (crop)

- **SAM 3:** a partir de un recorte de ejemplo, segmenta todas las instancias del mismo concepto en la imagen o vídeo.
- **Generalización:** ideal para tareas de conteo o seguimiento de objetos idénticos.


Segment everything

- **Cobertura completa:** genera una máscara para cada objeto detectable en la imagen sin prompts específicos.
- **Análisis exhaustivo:** útil para la inspección completa de escenas complejas.

Meta AI publica un **Segment Anything Playground**, un espacio interactivo para probar estos prompts sobre medios propios.

Marca un punto y mira la máscara

Un punto positivo propone el objeto entero; uno negativo retira la parte que sobra.



La máscara cubre la carrocería, la cabina y las ruedas.

Puntos colocados **1**

Esta escena reproduce el comportamiento que conviene anticipar, no la salida de un modelo concreto. Un punto positivo sobre la carrocería propone la furgoneta completa: carrocería, cabina y ruedas. Un punto negativo sobre las ruedas las retira sin volver a empezar. Un punto sobre el árbol añade otro objeto, porque el prompt señala una región y no una categoría. En SAM real la primera indicación puede resultar ambigua entre objeto, parte y subparte, y por eso algunas versiones devuelven varias máscaras candidatas con su puntuación.

Un clic elige el objeto

El punto positivo señala una región que debe pertenecer a la máscara.

Quieres segmentar una manzana entre otras frutas. ¿Qué prompt sirve para empezar?

☐ A Un punto positivo dentro de la manzana.

☐ B El nombre de la clase sin imagen.

☐ C Una métrica de precisión.

Respuesta A. Exacto: indica qué objeto quieres incluir.

La primera indicación puede admitir varias interpretaciones: objeto completo, parte o subparte. Por eso algunas versiones devuelven varias máscaras candidatas con puntuaciones.

Corregir sin volver a entrenar

Los nuevos clics añaden información sobre qué incluir y qué excluir.

La máscara incluye parte del fondo. ¿Qué harías?

- ☐ A Añadir un punto negativo sobre el fondo.
- ☐ B Subir la temperatura del modelo.
- ☐ C Cambiar el nombre del objeto.

Respuesta A. Exacto: el punto negativo señala qué región excluir.

En vídeo con SAM 2, una corrección puede actualizar la memoria y propagarse. La interacción debe evaluarse por calidad final y por número de clics o tiempo requerido.

Cuándo usar (y cuándo no) SAM

Úsalo si... (ideal para flexibilidad y zero-shot)

- **Segmentación zero-shot crítica:** necesitas segmentar objetos desconocidos, raros o que no existían en tu dataset de entrenamiento (por ejemplo microscopía o imagen submarina, underwater).
- **Vídeo y coherencia temporal:** requieres rastrear objetos que se mueven, ocultan y reaparecen sin entrenar un tracker específico, gracias a la memoria de SAM 2 y 3.
- **Interacción humana (human-in-the-loop):** estás construyendo herramientas de anotación de datos o edición donde el usuario refina el resultado con clics o cajas.
- **Búsqueda por conceptos (SAM 3):** necesitas encontrar todas las instancias de un concepto abstracto («tornillos oxidados») usando texto o ejemplos visuales, no solo puntos.
- **Escasez de datos:** no tienes miles de máscaras anotadas para entrenar un modelo supervisado tradicional.

Evítalo si... (mejor usar modelos supervisados clásicos)

- **Restricciones de hardware extremas (edge):** necesitas inferencia en milisegundos en dispositivos IoT o móviles antiguos. Aunque eficiente, SAM 3 requiere GPU potentes (H200) para latencias de unos 30 ms en cargas altas.
- **Entorno cerrado y repetitivo:** si tu problema es «detectar botellas en una cinta transportadora», con clases fijas y fondo controlado, un modelo ligero como RF-DETR-Seg será mucho más rápido y barato de desplegar.
- **Razonamiento complejo:** SAM 3 entiende frases nominales simples. Si necesitas lógica compleja, necesitas un VLM.

La máscara no nombra la especie

SAM delimita; otra señal debe reconocer, decidir o justificar.

Necesitas saber qué especie aparece y segmentarla.

- ☐ **A** Combinar una señal de categoría con SAM.
- ☐ **B** Usar solo una máscara sin revisar.
- ☐ **C** Eliminar los prompts.

Respuesta A. Exacto: SAM aporta la máscara, otra parte debe aportar la categoría.

SAM resulta valioso con poca anotación, interacción humana o vídeo. Un modelo supervisado pequeño puede ser más rápido y barato para clases estables y fondos controlados. Siempre hay que evaluar bordes, objetos pequeños, oclusiones y consumo de memoria.

Segmenta y corrige

Prueba cómo cambian las máscaras con puntos positivos y negativos.

1. Guarda una copia en Drive.
2. Segmenta con un punto.
3. Refina y compara máscaras.

Abrir en Colab ↗

Empieza con un punto positivo y añade un punto negativo donde la máscara invada el fondo. Compara número de interacciones, contorno y objetos pequeños. Comprueba qué versión carga el cuaderno: texto, memoria temporal y ejemplares no están disponibles en todos los modelos SAM.