

Más formas de ver


Una imagen puede revelar postura, texto, detalle, transparencia, correspondencias y profundidad.

Pose Articulaciones y movimiento.	OCR Texto y estructura documental.	Superresolución Más píxeles y detalle plausible.
Fondo Objeto y transparencia.	Matching Puntos comunes entre vistas.	Profundidad Distancia estimada por píxel.

Este tema reúne tareas que amplían el repertorio del curso. La estimación de pose localiza puntos clave; el OCR extrae texto; la superresolución restaura imágenes; la eliminación de fondo estima transparencias; el image matching encuentra correspondencias; y la profundidad monocular aproxima la estructura 3D.

De píxeles a esqueleto

La pose convierte el cuerpo en coordenadas, conexiones y confianza.



COCO define 17 puntos para cabeza, brazos y piernas; cada predicción añade una confianza.

La salida habitual es una lista de coordenadas (x, y) y una puntuación por punto. Conectar hombros, codos, muñecas, caderas, rodillas y tobillos crea una estructura geométrica que permite medir movimiento y ángulos articulares.

Primero persona, después pose

El enfoque top-down recorta cada persona antes de localizar sus articulaciones.



ViTPose y HRNet suelen usarse en pipelines top-down. Este enfoque maneja bien cambios de escala, pero su coste crece con el número de personas. El cuaderno aplica exactamente esta secuencia: RT-DETR detecta personas y ViTPose estima sus puntos.

Tres maneras de agrupar

La diferencia principal es cuándo se detectan las personas y cuándo se asignan los puntos.

Top-down Persona primero; pose después. Preciso, con coste por persona.	Bottom-up Puntos primero; agrupación después. Útil en escenas concurridas.	Una etapa Cajas y puntos en una pasada. Buen equilibrio para tiempo real.
---	--	---

OpenPose popularizó el enfoque bottom-up. Modelos de una etapa como YOLO-Pose predicen detección y keypoints conjuntamente. La elección depende de densidad de personas, latencia, hardware, tamaño de los sujetos y precisión requerida; no existe un ganador universal.

Elegir por el escenario

La arquitectura importa menos que el número de personas, el dispositivo y el error tolerable.

MediaPipe

Aplicaciones interactivas, cuerpo, manos o cara.

YOLO-Pose

Detección multipersona con una sola red.

OpenPose

Referencia bottom-up, influyente y exigente.

HRNet / ViTPose

Pipelines top-down orientados a precisión.

Antes de comparar modelos hay que fijar el dataset, resolución, hardware y objetivo. MediaPipe prioriza integración y eficiencia; YOLO-Pose simplifica el tiempo real; OpenPose es una referencia académica; HRNet y ViTPose son opciones top-down. Las capacidades concretas dependen de la versión y del checkpoint.

Medir un esqueleto

OKS normaliza el error por tamaño de la persona y tolerancia de cada articulación.



Object Keypoint Similarity resume cuánto se parecen dos conjuntos de puntos.

Dos articulaciones fallan cinco píxeles. ¿Penaliza OKS siempre igual?

- ☐ A Sí, solo cuenta la distancia en píxeles.
- ☐ B No, depende de escala y articulación.
- ☐ C No, solo cuenta cuántas personas hay.

Respuesta B. Exacto: normaliza por tamaño y usa una tolerancia específica por keypoint.

OKS cumple un papel parecido a IoU en detección, pero compara keypoints visibles. Un mismo error en píxeles pesa de forma distinta según la escala de la persona y la variabilidad habitual del punto. A partir de umbrales de OKS se calculan AP y AR de pose.

Movimiento convertido en datos

Ángulos y trayectorias permiten analizar técnica, ergonomía y rehabilitación.



Deporte y fitness · seguridad industrial · salud y rehabilitación.

Las aplicaciones incluyen contar repeticiones, medir ángulos, detectar posturas de riesgo, generar alertas ante caídas, validar ejercicios de fisioterapia y analizar la marcha. En usos sensibles se debe validar el sistema por población, cámara, ropa, postura y entorno.

Lo oculto sigue siendo incierto

Una articulación puede desaparecer detrás del cuerpo, otra persona o un objeto.



La memoria temporal y los modelos 3D pueden proponer posiciones plausibles para partes ocultas, pero no recuperan información observada. La interfaz debe conservar la incertidumbre en vez de presentar todos los puntos como igualmente fiables.

De imagen a información

El OCR moderno puede reconocer texto y, con otros modelos, reconstruir la estructura del documento.



Los sistemas clásicos suelen separar preprocesamiento, detección y reconocimiento. TrOCR usa un encoder visual y un decoder de texto en un sistema end-to-end, especialmente adecuado para imágenes ya recortadas. Un VLM puede interpretar el contexto y devolver una estructura, pero exige comprobar campos y formatos.

La salida decide la herramienta


Una línea, una página completa y una factura estructurada requieren pipelines distintos.

EasyOCR Detección y lectura multilínea para prototipos rápidos.	TrOCR Reconocimiento transformer sobre líneas o palabras recortadas.	VLM Comprensión documental y salida estructurada con validación.
---	--	--

EasyOCR integra detección y reconocimiento. TrOCR se centra en reconocer una región de texto y ofrece checkpoints para impreso o manuscrito. Los VLM pueden contestar preguntas sobre documentos o producir JSON, pero conviene validar cada campo y usar OCR especializado cuando la exactitud carácter a carácter sea prioritaria.

Más detalle, no más verdad

La red genera una versión de mayor resolución compatible con patrones aprendidos.



Swin2SR recupera bordes y texturas plausibles frente a una ampliación bicúbica.

Swin2SR usa bloques Swin Transformer V2 para superresolución y restauración de artefactos de compresión. Puede producir una imagen más nítida, pero los detalles generados son estimaciones: no prueban qué había en la escena original.

Mejorar sin inventar evidencia

La utilidad visual puede aumentar aunque la fidelidad científica no lo haga.

Archivos restaurar fotos y vídeo antiguos.

Catálogo homogeneizar imágenes de producto.

Medicina validar antes de extraer conclusiones.

Una superresolución muestra una mancha nueva en una imagen médica. ¿Qué concluyes?


- ☐ A La mancha estaba en el original.
- ☐ B Hay que validarla contra el original y el proceso clínico.
- ☐ C Una mayor resolución siempre elimina el error.

Respuesta B. Exacto: la mejora visual no convierte el detalle generado en evidencia.

También puede ayudar a visualizar imágenes aéreas o satelitales. En medicina, inspección o investigación forense, una textura inventada puede confundirse con una señal real. La salida mejorada nunca debe reemplazar al original ni usarse para diagnóstico sin validación específica y supervisión experta.

Separar con transparencia

Los bordes suaves necesitan una máscara continua, no una decisión binaria.



Un canal alfa conserva transiciones en pelo, vidrio, humo y otros contornos difíciles.

El alpha matting estima opacidades entre 0 y 1 para mezclar primer plano y fondo. Modelos como RMBG producen una máscara suave que puede convertirse en canal alfa. Conviene revisar halos, transparencias, objetos finos y la licencia del checkpoint antes de usarlo en producción.

La misma escena, otra vista

El matching une puntos que representan el mismo lugar pese a perspectiva, luz u oclusión.



SuperPoint o DISK detectan y describen puntos; LightGlue propone correspondencias y descarta muchas ambiguas.

Los métodos aprendidos ofrecen robustez en escenas difíciles, mientras SIFT u ORB siguen siendo útiles cuando importan simplicidad, coste o ausencia de datos. Tras el matching se suele aplicar una comprobación geométrica —por ejemplo, RANSAC— para eliminar correspondencias incompatibles con la cámara.

Correspondencias que crean geometría


Varios puntos compartidos permiten relacionar cámaras, movimiento y estructura 3D.

Fotogrametría Reconstruir geometría y posiciones de cámara.	SLAM Localizar un robot mientras construye un mapa.	Panoramas Alinear imágenes solapadas en una vista continua.
---	---	---

Structure from Motion triangula puntos vistos desde varias cámaras. SLAM combina localización y mapa durante el movimiento. El stitching estima transformaciones entre imágenes para fusionarlas; necesita solape suficiente y una geometría compatible.

Una imagen, muchas distancias

La profundidad monocular asigna a cada píxel una posición relativa en la escena.



Entrada RGB



Profundidad estimada

Depth Anything V2 es un modelo fundacional para profundidad monocular. Sus modelos generales producen profundidad relativa y se entrenan con una combinación de datos etiquetados y pseudoetiquetados. Un mapa de color ayuda a visualizar el orden de las superficies, pero el color no equivale automáticamente a metros.

Un mapa, cuatro usos

La distancia por píxel permite seleccionar planos, navegar y aproximar una escena 3D.

Bokeh

Separar sujeto y fondo por distancia.

Nube de puntos

Proyectar RGB y profundidad en 3D.

Navegación

Detectar obstáculos y espacio libre.

Filtro

Conservar solo un intervalo de profundidad.

Una nube de puntos necesita además los parámetros de cámara y una escala coherente. Para robótica de seguridad, una predicción monocular debe validarse y, con frecuencia, combinarse con sensores o restricciones temporales.

Cerca y lejos no son metros

La profundidad relativa ordena la escena; la métrica intenta recuperar distancias físicas.

Relativa compara qué está delante o detrás.

Métrica estima unidades físicas.

Calibración aporta geometría y escala de cámara.

Necesitas saber si un obstáculo está a 1,5 metros. ¿Basta un mapa relativo normalizado?

- ☐ **A** Sí, porque el color ya representa metros.
- ☐ **B** Sí, si la imagen tiene buena resolución.
- ☐ **C** No, hace falta escala métrica o calibración.

Respuesta C. Exacto: necesitas un modelo métrico, calibración u otra referencia de escala.

Los checkpoints generales de Depth Anything V2 estiman profundidad relativa. Para trabajar en metros se necesita un modelo entrenado para profundidad métrica, calibración u otra fuente de escala. Normalizar un mapa entre 0 y 1 solo cambia su representación; no lo convierte en distancia física.

Elige una tarea y pruébala

El cuaderno reúne pose, OCR, superresolución, fondo y profundidad con modelos de Hugging Face.

1. Guarda una copia en Drive.
2. Ejecuta una tarea con tu imagen.
3. Compara la salida y combina dos tareas.

[Abrir en Colab](#) ↗

El cuaderno usa RT-DETR + ViTPose, TrOCR, Swin2SR, RMBG-1.4 y Depth Anything V2. Cada bloque descarga sus pesos la primera vez y algunos funcionan mejor con GPU; la disponibilidad de GPU gratuita en Colab no está garantizada. Empieza por una sola tarea, conserva la imagen original y describe qué errores observas. Como ampliación, combina dos salidas en un pipeline. Con esta práctica termina el recorrido del curso.